

NATIONAL UNIVERSITY OF ENGINEERING
COLLEGE OF ECONOMICS AND STATISTICAL
ENGINEERING
STATISTICAL ENGINEERING PROGRAM



INFORME DE CURSO CAPSTONE

TITLE

“Comparative Evaluation of the Holt-Winters and SARIMA Models for the Forecast of the CPI in Transportation in Metropolitan Lima from september to december 2024”

TÍTULO

“Evaluación Comparativa de los Modelos Holt-Winters y SARIMA para el Pronóstico del IPC en el Sector Transporte de Lima Metropolitana de septiembre a diciembre de 2024”

BY:

Michell Karen Angélica Matias Tello

SUPERVISOR:

Leighton L. Estrada Rayme

LIMA-PERÚ
2024

Abstract

In this research, a comparative evaluation of the Holt-Winters and SARIMA models was carried out for forecasting the Consumer Price Index (CPI) in transportation in Metropolitan Lima from September to December 2024. The main objective of this study was to compare the accuracy of both models to determine which one provides better results in forecasting the CPI in the transportation sector. This analysis was based on the relevance of the CPI as a fundamental economic indicator that reflects price fluctuations and their impact on the cost of living of the population.

Using a quantitative approach, historical CPI data in transportation were analyzed, identifying trend and seasonality patterns that supported the selection of the models. The Holt-Winters model was evaluated for its ability to capture seasonal patterns through exponential smoothing techniques, while the SARIMA model integrated autoregressive and moving average components adjusted for seasonality.

The results showed that the SARIMA(1,0,1)(1,0,1)₁₂ model outperformed the Holt-Winters model in terms of forecast accuracy, recording lower metrics of mean absolute error (MAE: 0.1167 vs. 0.126), mean absolute percentage error (MAPE: 12.64 % vs. 13.91 %) and root mean square error (RMSE: 0.1410 vs. 0.172). These differences were statistically significant, indicating a greater capacity of SARIMA to model both seasonality and non-seasonal fluctuations. Therefore, it is recommended to use the SARIMA model to forecast the behavior of the CPI in the transportation sector in Metropolitan Lima for the period from September to December 2024.

Keywords: CPI, Transport, SARIMA, Holt-Winters, Forecast

Resumen

En la presente investigación se realizó una evaluación comparativa de los modelos Holt-Winters y SARIMA para el pronóstico del Índice de Precios al Consumidor (IPC) en transporte en Lima Metropolitana de septiembre a diciembre de 2024. El objetivo principal de este estudio fue comparar la precisión de ambos modelos para determinar cuál proporciona mejores resultados en el pronóstico del IPC en el sector transporte. Este análisis se basó en la relevancia del IPC como indicador económico fundamental que refleja las fluctuaciones de precios y su impacto en el costo de vida de la población.

Mediante un enfoque cuantitativo, se analizaron datos históricos del IPC en transporte, identificando patrones de tendencia y estacionalidad que respaldaron la selección de los modelos. El modelo Holt-Winters fue evaluado por su capacidad para capturar patrones estacionales a través de técnicas de suavizamiento exponencial, mientras que el modelo SARIMA integró componentes autorregresivos y de media móvil ajustados a la estacionalidad.

Los resultados mostraron que el modelo SARIMA(1,0,1)(1,0,1)₁₂ superó al modelo Holt-Winters en términos de precisión del pronóstico, registrando métricas más bajas de error absoluto medio (MAE: 0.1167 vs. 0.126), error porcentual absoluto medio (MAPE: 12.64 % vs. 13.91 %) y raíz del error cuadrático medio (RMSE: 0.1410 vs. 0.172). Estas diferencias fueron estadísticamente significativas, indicando una mayor capacidad de SARIMA para modelar tanto la estacionalidad como las fluctuaciones no estacionales. Por lo tanto, se recomienda utilizar el modelo SARIMA para prever el comportamiento del IPC en el sector transporte en Lima Metropolitana para el periodo de septiembre a diciembre del 2024.

Palabras clave: IPC, Transporte, SARIMA, Holt-Winters, Pronóstico

Índice

1. INTRODUCCIÓN	7
1.1. Descripción de la situación problemática	7
1.2. Formulación del problema	8
1.2.1. Problema general	8
1.2.2. Problema específico	8
1.3. Objetivos de la investigación	8
1.3.1. Objetivo general	8
1.3.2. Objetivos específicos	8
1.4. Justificación, alcances y Limitaciones	8
1.4.1. Justificación	8
1.4.2. Alcances	10
1.4.3. Limitaciones	10
2. FUNDAMENTOS TEÓRICOS	11
2.1. Antecedentes	11
2.1.1. Antecedentes nacionales	11
2.1.2. Antecedentes internacionales	12
2.2. Bases Teóricas	14
2.2.1. Índice de Precio al Consumidor(IPC)	14
2.2.2. IPC y la Inflación General	15
2.2.3. IPC y Comparaciones Internacionales de Inflación	15
2.2.4. Conceptos Generales	16
2.3. Metodología de Box Jenkins	18
2.3.1. Modelos Lineales Estacionarios	18
2.3.2. Modelos lineales no Estacionarios	20
2.4. Metodología de Holt-Winters	23
2.4.1. Holt-Winters aditivo	24
2.4.2. Holt-Winters multiplicativo	25
2.4.3. Estimación de α , β y γ e indicadores de error del modelo	25
2.5. Métricas de desempeño	25
2.5.1. Prueba Dickey-Fuller	25
2.5.2. Criterios de información	26
2.5.3. Estadístico Durbin-Watson	26
2.5.4. Error Absoluto Medio (MAE)	27
2.5.5. Raíz del Error Cuadrático Medio (RMSE)	27
2.5.6. Error Porcentual Absoluto Medio (MAPE)	27
3. MATERIALES, MÉTODOS Y PROCEDIMIENTOS	28
3.1. Tipo, nivel y diseño de la investigación	28
3.1.1. Tipo de investigación	28
3.1.2. Nivel de investigación	28
3.1.3. Diseño de la investigación	28
3.1.4. Población y muestra	28
3.1.5. Técnicas de recolección de datos	28

3.1.6.	Descripción de la variable	29
3.1.7.	Herramientas y Software	29
3.2.	Procedimiento de análisis	29
3.2.1.	Metodología de SARIMA	29
3.2.2.	Metodología de Holt - Winters	30
4.	PRESENTACIÓN Y ANÁLISIS DE RESULTADOS	33
4.1.	Análisis Exploratorio	33
4.1.1.	Suavizado de la Serie Temporal	34
4.1.2.	Análisis mediante Gráfico de Caja y Bigotes	35
4.1.3.	Evaluación de Dependencia Temporal: ACF y PACF	36
4.1.4.	Verificación de Estacionariedad	39
4.1.5.	Transformación Logarítmica de la Serie	39
4.2.	Modelamiento SARIMA	41
4.3.	Modelamiento Holt-Winters	46
4.4.	Comparación de Modelos	50
5.	CONCLUSIONES	51
6.	BIBLIOGRAFÍA	52
7.	ANEXOS	55
7.1.	Normas, Estándares y Regulaciones	55
7.1.1.	Norma NTP-ISO 9001:2001	55
7.1.2.	Norma NTP-ISO 3534-1:2015	56
7.1.3.	Normas adicionales relacionadas	57
7.2.	Restricciones Múltiples	58
7.3.	Código del Programa	59
7.4.	Hojas de Datos	64

Índice de figuras

1.	IPC de Lima Metropolitana por División de Consumo (Julio 2024) . . .	9
2.	Metodología de Box-Jenkins	30
3.	Metodología de Holt-Winters	32
4.	Serie de tiempo del IPC en transporte.	33
5.	Comparación de la serie de tiempo original y la serie suavizada	35
6.	Serie de tiempo suavizada del IPC en transporte.	35
7.	Gráfico de caja y bigotes del IPC en transporte.	36
8.	Correlograma del IPC en transporte	37
9.	Correlograma parcial del IPC en transporte	38
10.	Descomposición de los componentes de la serie de tiempo	38
11.	Comparación de la serie original y la serie transformada	40
12.	Residuales del modelo SARIMA(0,1,1)(0,1,1) ₁₂	42
13.	Residuales del modelo SARIMA(1,0,1)(1,0,1) ₁₂	42
14.	Residuales del modelo SARIMA(2,0,0)(0,1,1) ₁₂	43
15.	Residuales del modelo SARIMA(1,0,1)(0,1,1) ₁₂	43
16.	Residuales del modelo SARIMA(0,0,1)(1,1,1) ₁₂	44
17.	Vista gráfica de los pronósticos del modelo SARIMA	45
18.	Pronósticos iniciales utilizando el modelo Holt-Winters Aditivo	47
19.	Gráfico de líneas del IPC en el sector transporte y su pronóstico	47
20.	Optimización de parámetros usando SOLVER	48
21.	Gráfico de líneas del IPC y su pronóstico con parámetros optimizados	49
22.	Gráfico de los pronósticos sep-dic del 2024 con parámetros optimizados	50

Índice de cuadros

1.	Resumen de estadísticas descriptivas de IPC Transporte	34
2.	Resultados del Test de Dickey-Fuller	39
3.	Resultados de los modelos SARIMA	41
4.	Resultados del Test de Ljung-Box	41
5.	Resumen de Modelos SARIMA y sus Medidas de Error	44
6.	Pronósticos para los meses de septiembre-diciembre de 2024	45
7.	Valores iniciales	46
8.	Parámetros optimizados	49
9.	Métricas de Error de pronósticos Holt-Winters	49
10.	Pronósticos del IPC en el sector transporte	50
11.	Comparación de las métricas de rendimiento de los modelos	50

1. INTRODUCCIÓN

1.1. Descripción de la situación problemática

La situación problemática del Índice de Precios al Consumidor (IPC) en el ámbito del transporte en Perú ha sido un factor importante en la economía del país. El transporte es uno de los rubros con mayor peso en el cálculo del IPC, y cualquier fluctuación en los precios de este sector puede afectar significativamente el costo de vida. En los últimos años, diversos factores como el aumento de los combustibles, la ineficiencia en la infraestructura vial, y la falta de políticas públicas efectivas han generado un impacto considerable en los precios del transporte, lo cual se refleja en el IPC de Lima Metropolitana y otras regiones del país (Forbes Staff, 2023).

Uno de los principales factores que ha impulsado el aumento de los precios del transporte es el alza de los combustibles. Perú, a pesar de contar con recursos energéticos propios, depende en gran medida de las importaciones de petróleo y sus derivados. Las fluctuaciones internacionales en el precio del crudo y la devaluación de la moneda nacional han llevado a incrementos en los precios del combustible. Estos aumentos se trasladan directamente a los costos del transporte público y privado, afectando el bolsillo de los consumidores y generando una presión inflacionaria (Infobae, 2022).

La infraestructura de transporte en el país es otro aspecto que agrava la situación. A pesar de las inversiones en carreteras y en transporte público en los últimos años, la calidad y la cobertura de estas infraestructuras siguen siendo insuficientes. Esto genera ineficiencias y costos adicionales tanto para el transporte de personas como de mercancías. Las congestiones en las principales ciudades, especialmente en Lima Metropolitana, y la falta de alternativas de transporte masivo como trenes o metros eficientes, encarecen los tiempos de desplazamiento y el costo del transporte (ESAN, s.f.).

Existe una falta de políticas públicas coherentes y a largo plazo para abordar estos problemas ha exacerbado la situación. Aunque se han implementado programas de subsidios ocasionales para el transporte, no han sido suficientes para contrarrestar el efecto del alza de precios. Se necesita una visión más integral que incluya la promoción de energías limpias, la mejora de la infraestructura de transporte público y la formalización del sector, lo que permitiría una mayor estabilidad en los precios y, por ende, un impacto menos negativo en el IPC. Sin estas reformas, el transporte seguirá siendo un factor que impulsa la inflación en Perú (ESAN, s.f.).

Para afrontar el problema del aumento del IPC en el ámbito del transporte en Lima Metropolitana, emplearemos una evaluación comparativa de dos modelos de pronóstico: Holt-Winters y SARIMA. Ambos enfoques permiten modelar series temporales con características estacionales, lo cual es crucial para capturar las variaciones en los precios del transporte que tienden a seguir patrones repetitivos a lo largo del año. El modelo Holt-Winters se basa en suavizados exponenciales que ajustan tendencias y estacionalidad, mientras que el modelo SARIMA combina componentes autorregresivos y de media móvil con un tratamiento especial para la estacionalidad. Esta metodología permitirá identificar cuál de estos modelos ofrece pronósticos más precisos y adecuados para prever el comportamiento del IPC en transporte, considerando el período de

septiembre a diciembre de 2024.

1.2. Formulación del problema

1.2.1. Problema general

¿Cuál de los modelos, Holt-Winters o SARIMA, proporciona pronósticos más precisos del IPC en el sector Transporte en Lima Metropolitana de septiembre a diciembre de 2024?

1.2.2. Problema específico

- ¿Qué patrones de tendencia, estacionalidad y variabilidad presenta la serie de tiempo del IPC en el sector transporte en Lima Metropolitana durante los últimos años?
- ¿Qué tan bien se ajusta el modelo Holt-Winters a los datos históricos del IPC en el sector transporte en Lima Metropolitana?
- ¿Cómo se ajusta el modelo SARIMA a los datos históricos del IPC en el sector transporte en Lima Metropolitana?

1.3. Objetivos de la investigación

1.3.1. Objetivo general

Comparar la precisión de los modelos Holt-Winters y SARIMA para el pronóstico del Índice de Precios al Consumidor en el sector Transporte en Lima Metropolitana durante el periodo de septiembre a diciembre de 2024.

1.3.2. Objetivos específicos

- Analizar la serie de tiempo del IPC en transporte en Lima Metropolitana para identificar patrones de tendencia, estacionalidad y variabilidad durante los últimos años.
- Evaluar el ajuste del modelo Holt-Winters a los datos históricos del IPC en el sector transporte en Lima Metropolitana
- Aplicar y ajustar el modelo SARIMA a los datos históricos del IPC en el sector transporte en Lima Metropolitana

1.4. Justificación, alcances y Limitaciones

1.4.1. Justificación

La investigación sobre el pronóstico del Índice de Precios al Consumidor (IPC) en el sector transporte en Lima Metropolitana es fundamental debido a la relevancia que este sector tiene en la economía del país. La fluctuación de los precios del transporte impacta directamente en el costo de vida de los ciudadanos, afectando su capacidad

de acceso a bienes y servicios. Un ejemplo claro de esta fluctuación se refleja en los datos del IPC de julio de 2024, presentados en la fila 7 de la Figura 1, donde el sector transporte muestra un aumento del 0,12 % en comparación con el mes anterior y un acumulado del 4,85 % entre agosto de 2023 y julio de 2024. Este incremento responde, en parte, a la estacionalidad asociada a las festividades, que generalmente generan una mayor demanda de servicios de transporte, provocando un incremento en los precios.

En este contexto, es crucial contar con modelos de pronóstico que permitan anticipar las tendencias de precios y, por ende, mitigar los efectos negativos sobre los consumidores. El uso de los modelos Holt-Winters y SARIMA es pertinente en este estudio debido a su capacidad para manejar series temporales con características estacionales y tendencias. El modelo Holt-Winters, que se basa en suavizados exponenciales, permite capturar patrones de estacionalidad y tendencia de manera efectiva, mientras que el modelo SARIMA combina elementos autorregresivos y de media móvil, lo que lo hace adecuado para series con estacionalidad compleja.

Índice de Precios al Consumidor de Lima Metropolitana

Julio 2024

Divisiones de Consumo	Ponderación	Variación %		
		Julio 2024	Ene. - Jul.24	Ago.23 - Jul.24
Índice General	100,000	0,24	1,81	2,13
1. Alimentos y bebidas no alcohólicas	22,967	0,34	1,33	-0,94
2. Bebidas alcohólicas, tabaco y estupefacientes	1,606	0,12	2,93	4,01
3. Prendas de vestir y calzado	4,196	0,02	0,50	1,15
4. Alojamiento, agua, electricidad, gas y otros combustibles	10,554	0,12	1,51	2,11
5. Muebles, artículos para el hogar y la conservación ordinaria del hogar	5,106	0,10	0,86	1,38
6. Salud	3,484	0,02	1,37	1,92
7. Transporte	12,397	0,63	2,23	4,85
8. Comunicaciones	4,771	0,00	0,06	-0,40
9. Recreación y cultura	3,958	0,31	1,19	2,03
10. Educación	8,607	0,06	4,98	5,36
11. Restaurantes y hoteles	15,885	0,16	2,02	3,79
12. Bienes y servicios diversos	6,469	0,15	1,60	3,08

Fuente: Instituto Nacional de Estadística e Informática

Figura 1: IPC de Lima Metropolitana por División de Consumo (Julio 2024)

Al comparar ambos enfoques, se busca identificar cuál de ellos ofrece pronósticos más precisos para el IPC en el sector transporte, lo que permitirá tomar decisiones informadas. Dado el reciente comportamiento del IPC en transporte, este análisis cobra mayor relevancia, ya que proporciona información valiosa para las autoridades y los responsables de la formulación de políticas públicas. Al entender mejor las dinámicas del IPC en el transporte, se podrán implementar medidas que estabilicen los precios y mejoren la calidad del servicio, beneficiando a los usuarios finales. Además, los resultados de este estudio pueden servir como base para futuros análisis en otros sectores, ampliando el enfoque de la investigación hacia un desarrollo más integral de la economía peruana.

1.4.2. Alcances

La investigación se centrará en el análisis de los datos históricos del IPC en transporte en Lima Metropolitana desde un enfoque cuantitativo, utilizando herramientas estadísticas avanzadas para la modelización y pronóstico. Se contempla un periodo de estudio que abarca desde los últimos años hasta el final de 2024, lo que permitirá identificar tendencias y patrones relevantes en los precios del transporte.

El alcance del estudio incluye la evaluación del ajuste de los modelos Holt-Winters y SARIMA, así como la comparación de sus rendimientos a través de métricas de evaluación adecuadas. Los resultados obtenidos podrán ser utilizados por entidades gubernamentales, empresas de transporte y organismos de regulación para desarrollar estrategias que optimicen la gestión del sector, contribuyendo a la mejora de la calidad de vida de los ciudadanos.

Adicionalmente, se considerará la posibilidad de extender el análisis a otros sectores económicos en el futuro, utilizando los modelos desarrollados como referencia. Esto permitirá una visión más amplia sobre la dinámica de precios en el país y su relación con diversos factores económicos y sociales.

1.4.3. Limitaciones

Cambios en las Condiciones Económicas: La investigación se basa en datos históricos, lo que significa que cualquier cambio inesperado en la economía, como crisis económicas, cambios en políticas gubernamentales o eventos globales (como pandemias) pueden alterar las dinámicas del IPC en transporte, limitando la aplicabilidad de los modelos a futuro.

Modelos Estacionales: Aunque los modelos Holt-Winters y SARIMA son efectivos para series temporales con estacionalidad, pueden no capturar adecuadamente todos los factores que afectan el IPC en transporte, como cambios abruptos en la demanda o variaciones en la oferta debido a situaciones excepcionales.

Interacción con Otros Sectores: El IPC en transporte no opera de manera aislada; está influenciado por otros sectores de la economía, como la alimentación, la vivienda y la energía. Esta interconexión puede complicar la identificación de patrones y hacer que los pronósticos sean menos precisos si no se consideran esos efectos intersectoriales.

Generalización de Resultados: Los hallazgos de la investigación se centrarán en Lima Metropolitana, lo que puede limitar la generalización de los resultados a otras regiones del país que pueden tener características económicas y sociales diferentes.

Suposiciones de los Modelos: Ambos modelos utilizados tienen ciertas suposiciones inherentes (como la linealidad y la normalidad de los residuos), que si no se cumplen en los datos analizados, pueden afectar la validez de los resultados.

2. FUNDAMENTOS TEÓRICOS

2.1. Antecedentes

2.1.1. Antecedentes nacionales

En el trabajo titulado Implementación de mejoras en el pronóstico de demanda para la cadena de hoteles de Mountain Lodges of Perú, Puerta Ventura y Alayo Vilcarromero (2024) presentan una propuesta para optimizar la gestión de la demanda mediante modelos avanzados de predicción en la industria hotelera. El principal objetivo es aumentar la precisión en las proyecciones de demanda, lo que permitiría reducir costos operativos y mejorar la ocupación, aspectos cruciales para la competitividad en el sector turístico. Los autores evalúan métodos como el suavizado exponencial Holt-Winters, el modelo SARIMA y redes neuronales, analizando su precisión y costo-beneficio. Concluyen que SARIMA es la opción más eficiente, dado que captura patrones estacionales complejos y es particularmente efectivo en la predicción de series temporales, lo que se traduce en una mejora sustancial en la planificación de recursos, reducción de riesgos de sobreventa y subutilización de habitaciones, optimizando ingresos y satisfacción del cliente. La implementación de SARIMA implica tanto la capacitación del personal como la integración con los sistemas de gestión existentes, lo que refuerza la operatividad y eficiencia estratégica. Además, recomiendan actualizar periódicamente el modelo para mantener su relevancia y seguir mejorando los procesos operativos. Asimismo, subrayan que la adopción de este modelo no solo optimiza la precisión del pronóstico, sino que también promueve una gestión más estratégica, garantizando que la empresa se mantenga competitiva en un entorno desafiante y en constante cambio, haciendo énfasis en la importancia de continuar evaluando los procesos operativos para futuras mejoras.

En el artículo titulado Predicción del consumo de energía eléctrica residencial de la Región Cajamarca mediante modelos Holt-Winters, Eduar Jamis Mejía Vásquez y Salome Gonzales Chávez (2019) exploran métodos de predicción del consumo de energía eléctrica en el contexto de la región Cajamarca, Perú. El estudio tiene como objetivo principal aplicar el modelo Holt-Winters para proyectar el consumo residencial de electricidad a corto y mediano plazo, lo que resulta esencial para la planificación energética. La capacidad de realizar proyecciones precisas permite a los responsables de la toma de decisiones ajustar sus estrategias con base en predicciones confiables del consumo futuro. Para llevar a cabo esta tarea, los autores utilizan datos históricos de consumo de energía eléctrica desde 2005 hasta 2017, aplicando tanto la variante aditiva como multiplicativa del modelo Holt-Winters. A través de un análisis estadístico exhaustivo, identifican que el modelo aditivo ofrece el mejor ajuste con un error porcentual absoluto medio (MAPE) de 1,70. Este resultado es fundamental, ya que el modelo es capaz de capturar tanto la tendencia como la estacionalidad del consumo eléctrico en la región, lo que proporciona a los planificadores una herramienta útil para anticipar las demandas energéticas futuras. En las conclusiones del estudio destacan que, debido a factores económicos y demográficos, se espera un aumento en el consumo de energía eléctrica residencial en Cajamarca en los próximos años. La eficacia del modelo Holt-Winters aditivo no solo se subraya en términos de la precisión de las predicciones realizadas, sino también en la necesidad de planificar inversiones estratégicas en infraestructura para satisfacer el crecimiento de la demanda eléctrica. El análisis detallado realizado por los autores pone de relieve que la adecuada implementación de estos modelos de predicción

puede contribuir significativamente a la toma de decisiones en el sector energético, al ofrecer un marco sólido para anticipar el comportamiento futuro del consumo eléctrico en regiones en desarrollo como Cajamarca. Además, la capacidad de capturar patrones estacionales y de tendencia mediante el enfoque aditivo del modelo Holt-Winters permite a los gestores del sector contar con información clave para la formulación de políticas energéticas y la planificación de recursos.

En la investigación titulada Aplicación de los modelos Box-Jenkins y Holt-Winters para el pronóstico de los caudales mensuales en el río Shullcas en la estación Chamisería, Huancayo-Perú, Toribio Reyes Rodríguez (2019) se propone mejorar el pronóstico de los caudales mensuales del río Shullcas mediante la aplicación de modelos estadísticos. El estudio compara dos enfoques principales: el modelo de Box-Jenkins (ARIMA) y el modelo de Holt-Winters, con el objetivo de evaluar su capacidad para prever los caudales basándose en datos históricos, comprendidos entre 1985 y 2015, en la subcuenca del río Shullcas en la estación hidrométrica Chamisería. Los resultados del análisis revelan que el modelo de Holt-Winters no es adecuado para el pronóstico de caudales debido a la tendencia creciente de la serie temporal, la cual no es capturada adecuadamente por este modelo. En cambio, el modelo ARIMA $(1, 0, 0)(2, 1, 1)_{12}$ se identifica como el más apropiado para este fin, ya que presenta el menor valor en el criterio de información de Akaike (AIC), lo que sugiere un ajuste superior a los datos históricos y una mejor capacidad para capturar las fluctuaciones estacionales del caudal, las cuales están directamente vinculadas a las variaciones en las precipitaciones de la región. En sus conclusiones, el autor resalta la importancia de utilizar modelos estadísticos adecuados para la gestión y aprovechamiento de los recursos hídricos, recomendando el uso del modelo ARIMA para estudios futuros debido a su capacidad de ajuste a series temporales con estacionalidad marcada. Asimismo, subraya que un pronóstico preciso de los caudales es fundamental para la planificación y la sostenibilidad del uso del agua en la región de Huancayo, especialmente ante escenarios de creciente demanda y mayor variabilidad climática, lo que hace esencial contar con herramientas robustas para prever las fluctuaciones en la disponibilidad de este recurso natural clave.

2.1.2. Antecedentes internacionales

El artículo titulado Demand Forecasting in Food Retail: A Comparison Between the Holt-Winters and ARIMA Models de Veiga, Veiga, Catapan, Tortato y Da Silva (2014) analiza la precisión de dos modelos de pronóstico en el sector de alimentos perecederos, comparando las metodologías de Holt-Winters y ARIMA aplicadas a una serie temporal de productos lácteos perecederos. Los autores subrayan la importancia de un pronóstico preciso en este sector debido a la volatilidad de la demanda, cuyo objetivo principal fue identificar cuál de los dos modelos ofrecía mayor exactitud en la predicción de la demanda. Los resultados indicaron que el modelo Holt-Winters superó al ARIMA en términos de ajuste, mostrando un error porcentual absoluto medio (MAPE) de 4,97 % frente al 5,66 % del ARIMA. Además, el índice de desigualdad de Theil (U-Theil) fue más favorable para Holt-Winters, con un valor de 0,019 en comparación con el 0,031 obtenido por el modelo ARIMA. Aunque ambos modelos son ampliamente utilizados en la práctica, los autores concluyen que Holt-Winters logró capturar de manera más efectiva el comportamiento lineal de la serie temporal, lo que le permitió ajustarse me-

jor a los datos históricos. En términos de aplicabilidad, el estudio destaca que el modelo Holt-Winters es más adecuado para la previsión de la demanda de productos perecederos debido a su capacidad para manejar la estacionalidad de manera más precisa. Sin embargo, también se señala que ARIMA sigue siendo competitivo en ciertos contextos y que no debe ser descartado, ya que ofrece buenos resultados en situaciones donde las series temporales no presentan una fuerte componente estacional. El estudio concluye sugiriendo la necesidad de continuar investigando nuevas metodologías para mejorar las previsiones en la industria de alimentos perecederos, mencionando específicamente los modelos de redes neuronales como una posible vía para avanzar en la precisión del pronóstico. En este sentido, la investigación abre el camino para explorar enfoques híbridos que combinen la capacidad de modelos clásicos como Holt-Winters y ARIMA con técnicas más avanzadas que puedan adaptarse mejor a las complejidades del comportamiento de la demanda en el sector minorista de alimentos, donde la estacionalidad y la volatilidad son factores clave que influyen en la toma de decisiones.

Asimismo, en el artículo titulado Modelos de series temporales para pronóstico de la demanda eléctrica del sector de explotación de minas y canteras en Colombia de María Daniela Mariño, Adriana Arango, Laura Lotero y Maritza Jiménez (2021), se explora el uso de modelos de series temporales para predecir la demanda eléctrica en un sector no residencial clave en Colombia. Los autores destacan que, aunque el pronóstico de la demanda eléctrica ha sido ampliamente estudiado a nivel agregado, existe una falta de análisis específicos para sectores como el de minas y canteras. El objetivo de este estudio fue ajustar, validar y comparar tres modelos de series temporales —modelo de componentes aditivos, SARIMA y Holt-Winters— con el fin de identificar el más adecuado para pronosticar la demanda en este sector. Los resultados revelaron que el modelo Holt-Winters fue el más preciso, logrando el menor error en comparación con los otros dos modelos evaluados. En particular, se encontró que este modelo presentaba un error absoluto medio de 12.976 GWh, con un error porcentual alrededor del 3 %. Asimismo, en la validación gráfica y estadística de los modelos, se confirmó que el modelo Holt-Winters cumplía con los supuestos de normalidad, homocedasticidad e incorrelación de los residuos, lo que lo posicionó como la mejor opción en términos de desempeño predictivo. Aunque los tres modelos evaluados presentaron resultados satisfactorios, el modelo Holt-Winters sobresalió, destacándose por su capacidad de predicción más precisa. El estudio, por tanto, proporciona una herramienta útil para la planificación estratégica en el sector eléctrico colombiano, especialmente en el sector de minas y canteras, el cual representa una parte significativa de la demanda eléctrica no residencial del país. Finalmente, los autores sugieren que futuros estudios podrían enfocarse en el desarrollo y aplicación de modelos más complejos, tales como redes neuronales o algoritmos de inteligencia artificial, para continuar mejorando la precisión de los pronósticos de demanda eléctrica.

Por otro lado, en el artículo titulado La capacidad predictiva en los métodos Box-Jenkins y Holt-Winters: una aplicación al sector turístico de Jiménez Guerrero, Gázquez Abad y Sánchez Fernández (2006), se realiza un análisis comparativo de la capacidad predictiva de dos métodos de series temporales en el sector turístico de Almería, España. El estudio se enfoca en predecir la demanda de turistas alojados en hoteles de la región, comparando ambos modelos a través de indicadores de error como el RECM, MAE y MAPE, con el objetivo de determinar cuál ofrece mejores predicciones en un

entorno altamente estacional. Los resultados indican que tanto el modelo Box-Jenkins (ARIMA) como el Holt-Winters son útiles para predecir el número de turistas, aunque sus capacidades predictivas varían según los periodos del año. El modelo Holt-Winters presentó menores errores durante los meses de alta demanda turística, mientras que el modelo Box-Jenkins mostró mejor desempeño en los meses de baja estacionalidad. Los errores absolutos medios (MAE) y los errores absolutos medios porcentuales (MAPE) fueron más bajos en el modelo ARIMA, sugiriendo una mayor precisión global. Sin embargo, en los periodos de alta estacionalidad, Holt-Winters superó a ARIMA en términos de error. En conclusión, los autores afirman que, si bien ambos modelos son efectivos, el modelo Box-Jenkins presenta una ligera superioridad en cuanto a precisión global. No obstante, debido a la naturaleza estacional del turismo, sugieren que el uso de técnicas más avanzadas, como redes neuronales o algoritmos genéticos, podría mejorar la capacidad predictiva en estudios futuros. Estos hallazgos tienen implicaciones importantes para la planificación estratégica del sector turístico, ya que permiten a los gestores anticiparse con mayor certeza a las fluctuaciones de la demanda.

2.2. Bases Teóricas

2.2.1. Índice de Precio al Consumidor (IPC)

De acuerdo con Parkin (2007), la Oficina de Estadísticas Laborales de Estados Unidos (BLS, por sus siglas en inglés) establece los patrones de gasto de los hogares y selecciona la canasta básica mediante la Encuesta de Gastos del Consumidor. Este proceso es costoso y se realiza con poca frecuencia, utilizando datos de la encuesta de 1993-1995 para configurar la canasta actual. Antes de 1998, se basaba en datos de 1982-1984. La BLS ha planteado la necesidad de actualizaciones más frecuentes en el futuro. Una vez que se dispone de la información sobre precios, se procede a calcular el Índice de Precios al Consumidor (IPC), que implica tres pasos: determinar el costo de la canasta básica a precios del período base, calcular el costo de la canasta básica a precios del período actual y, finalmente, calcular el IPC para ambos períodos. Quispe (2003) señala que los índices son métodos estadísticos que permiten medir las diferencias porcentuales en un conjunto de variables, tomando como referencia un punto en el tiempo o en el espacio, ya sea en términos de precios, cantidades o valores de productos y servicios, así como variables relacionadas con programas sociales o temas culturales.

Fórmula del Cálculo del IPC

El IPC de Lima Metropolitana se calcula con la fórmula de Laspeyres, que comprende un conjunto de ponderaciones fijas y un conjunto de precios promedio relativos en el período base y a lo largo del tiempo (Instituto Nacional de Estadística e Informática (INEI, 2001).

La fórmula de Laspeyres se puede escribir de las siguientes maneras:

$$I_t^0 = \frac{\sum_{i=1}^n P_t Q_0}{\sum_{i=1}^n P_0 Q_0}$$

o

$$I_t^0 = \sum_{i=1}^n \left(\frac{P_t}{P_0} Q_0 \right)$$

Donde:

- I_t^0 = índice en el período "t", respecto al período base "0".
- P_t = precio del producto "i.en el período "t".
- P_0 = precio del producto "i.en el período base "0".
- Q_0 = cantidad consumida del producto "i.en el período base.
- n = número total de productos.

2.2.2. IPC y la Inflación General

Es crucial contar con medidas de inflación para establecer objetivos y evaluar el éxito de las políticas antiinflacionarias. Además, estas medidas son necesarias para la contabilidad empresarial y las cuentas nacionales, particularmente en relación con el poder adquisitivo. El análisis de los cambios en los precios relativos es igualmente importante, por lo que es esencial poder medir los cambios específicos en los precios de bienes y servicios individuales en relación con la inflación general (Armknrecht, 2006).

2.2.3. IPC y Comparaciones Internacionales de Inflación

Los IPC también son frecuentemente utilizados para realizar comparaciones internacionales de las tasas de inflación. Un ejemplo notable de esta práctica es el tratado de Maastricht, donde los países miembros de la Unión Europea decidieron usar el IPC para evaluar la convergencia de las tasas de inflación en la década de 1990, antes de la creación de la Unión Monetaria Europea. Aunque el IPC se centra más en la inflación al consumidor que en la inflación general, su uso para medir la convergencia se justifica, ya que se espera que la convergencia de los IPC esté estrechamente relacionada con la de la inflación general. Así, emplear una medida específica, en lugar de una medida general, puede ofrecer conclusiones similares sobre la convergencia y las desviaciones de los países con respecto a la media (Armknrecht, 2006).

2.2.4. Conceptos Generales

Canasta Básica: Se refiere al conjunto de bienes y servicios esenciales, principalmente alimentos, que se consideran necesarios para satisfacer las necesidades nutricionales y de bienestar de un hogar promedio.

Cantidad Ofrecida: Es la cantidad de un producto que los productores están dispuestos a vender en el mercado a un precio determinado en un período específico.

Coefficiente de Variación: Esta medida estadística expresa la variabilidad de un conjunto de datos en relación con su media, calculándose como la desviación estándar dividida por la media y expresándose en porcentaje.

Índices de Precio: Son herramientas utilizadas para medir la variación en los precios de un conjunto de bienes y servicios a lo largo del tiempo, comparándolos con un período base para evaluar la inflación o deflación.

Inflación: Se describe como el aumento sostenido del nivel general de precios de bienes y servicios en una economía, reflejando una disminución en el poder adquisitivo de la moneda. Se mide a través de varios índices, como el IPC.

Mercado: Se define como el espacio donde se lleva a cabo la interacción entre compradores y vendedores para el intercambio de bienes y servicios, que puede ser físico o virtual.

Poder Adquisitivo: Representa la capacidad de un individuo o grupo para comprar bienes y servicios con un ingreso específico, lo que refleja el nivel de vida.

Precio de Mercado: Es el valor monetario actual de un bien o servicio determinado, establecido por la interacción entre la oferta y la demanda en el mercado.

Valor: Se refiere a la importancia o utilidad de un bien o servicio, que se traduce en su precio en el mercado, reflejando lo que los consumidores están dispuestos a pagar.

Serie de tiempo: Una serie de tiempo es una lista de fechas, cada una de las cuales se asocia a un valor (un número). Las series de tiempo son un modo estructurado de representar datos. Visualmente, es una curva que evoluciona a lo largo del tiempo. Por ejemplo, las ventas diarias de un producto pueden representarse como una serie de tiempo (Vemorel, 2012).

Descomposición básica de una serie temporal

Valor observado = tendencia + estacionalidad + comp. irregular

$$Z_t = T_t + S_t + I_t \quad (1)$$

Donde:

- **Tendencia:** movimiento suave de la serie a largo plazo.

- **Estacionalidad:** movimientos de oscilación dentro del mes, año.
- **Irregular:** variaciones aleatorias alrededor de los componentes anteriores.

Clasificación de los modelos de series temporales

Serie no estacionaria: La principal característica es que la media, varianza y covarianza no son constantes a lo largo del tiempo, lo que dificulta su modelamiento. Sin embargo, para lograr que la serie permanezca estacionaria es necesario que sea diferenciada una o más veces (Ríos, 2008).

Serie estacionaria: Una serie estacionaria se define porque su media y varianza no cambian a lo largo del tiempo, y su covarianza depende únicamente del rezago (Ríos 2008). Estas características permiten modelar el proceso subyacente a partir de datos históricos.

Estacionalidad

Es crucial determinar la estacionalidad para explicar el comportamiento de una variable endógena, ya que parte de las fluctuaciones observadas se deben a factores estacionales. Por ejemplo, el Producto Bruto Interno (PBI) de un país tiende a incrementarse en diciembre o en fechas clave como el Día de la Madre, Fiestas Patrias, etc. Por lo tanto, es necesario estacionalizar las series para períodos de gran fluctuación (Antunez 2011).

Pruebas de estacionariedad

Para verificar la estacionariedad de una serie, se puede analizar su representación gráfica observando si la media y varianza son constantes. Si la serie no cumple estas condiciones, se concluye que no es estacionaria. (Brugger 2010).

Procesos estocásticos

Un proceso estocástico es una colección de variables aleatorias ordenadas en el tiempo o en el espacio, que describen la evolución de un sistema cuyo comportamiento es incierto o aleatorio. Matemáticamente, se define como una familia de variables aleatorias $\{X_t : t \in T\}$, donde t es el índice que puede representar tiempo (discreto o continuo) o alguna otra dimensión, y X_t es el estado del proceso en el tiempo t .

Estos procesos son útiles en áreas como la estadística, la física, la economía y las finanzas, ya que permiten modelar fenómenos que varían de manera no determinística. Un ejemplo clásico es el camino aleatorio (o random walk), que se utiliza para modelar precios de activos financieros, o los modelos de series temporales, que analizan datos que evolucionan a lo largo del tiempo, como la inflación o el clima.

Existen varios tipos de procesos estocásticos, como:

- **Proceso estocástico estacionario:** Su distribución conjunta es invariante con respecto al tiempo, y su media y varianza son constantes.

- Proceso estocástico no estacionario: Se refiere a series económicas que no cumplen con las condiciones de estacionariedad, ya que suelen evolucionar con tendencia creciente y oscilaciones alrededor de la misma (Hernandez 2005).
- Procesos de Markov: el estado futuro del proceso depende únicamente del estado presente y no de los estados pasados (propiedad de memoria limitada).
- Procesos Gaussianos: donde cada conjunto finito de variables aleatorias tiene una distribución conjunta normal.

2.3. Metodología de Box Jenkins

Según (Soriano, 2013): La metodología Box-Jenkins se refiere a una serie de procedimientos para identificar, ajustar y verificar los modelos de promedio móvil autorregresivo (más conocido por sus siglas en inglés ARIMA) con los datos de serie de tiempo. Los pronósticos proceden directamente de la forma del modelo ajustado, y es distinta de la mayoría de los métodos debido a que no supone un patrón particular en los datos históricos de las series que han de pronosticarse ARIMA (Modelos Autorregresivos Integrados de Medias Móviles); si la variable endógena de un período t es explicada por las observaciones de ella misma correspondientes a períodos anteriores añadiéndose, como en los modelos estructurales, un término de error.

2.3.1. Modelos Lineales Estacionarios

1. Modelo Autorregresivo AR(p)

El modelo autorregresivo AR(p) es uno de los componentes fundamentales en la modelización de series temporales. Este modelo asume que el valor actual de una serie temporal puede ser expresado como una combinación lineal de sus valores pasados y un término de error aleatorio. La notación AR(p) indica que el modelo utiliza p rezagos (valores pasados) de la serie para realizar la predicción.

Definición

Matemáticamente, un modelo autorregresivo de orden p se expresa de la siguiente manera:

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \varepsilon_t$$

donde:

- X_t es el valor actual de la serie temporal.
- $\phi_1, \phi_2, \dots, \phi_p$ son los coeficientes autorregresivos que se estiman a partir de los datos históricos.
- ε_t es un término de error aleatorio que se asume que sigue una distribución normal con media cero y varianza constante.

Propiedades

- **Estacionariedad:** Para que un modelo $AR(p)$ sea válido, la serie temporal debe ser estacionaria. Esto significa que sus propiedades estadísticas, como la media y la varianza, deben ser constantes en el tiempo. Si la serie no es estacionaria, se pueden aplicar transformaciones como la diferenciación para lograr estacionariedad.
- **Autocorrelación:** Los modelos $AR(p)$ se basan en la relación entre los valores pasados de la serie. La función de autocorrelación (ACF) puede ser utilizada para determinar la longitud adecuada del rezago p . Generalmente, se observa que los valores de autocorrelación decaen de manera gradual en un proceso AR .
- **Estimación de Parámetros:** Los parámetros ϕ_i se estiman típicamente usando el método de máxima verosimilitud o el método de mínimos cuadrados ordinarios. La estimación de los coeficientes es crucial para asegurar que el modelo se ajuste adecuadamente a los datos.

2. Modelos de Medias Móviles $MA(q)$

En un modelo $MA(q)$, el valor de la serie en el momento t se expresa como una combinación de innovaciones. Existe una relación entre los modelos AR y los modelos MA . Una alternativa de modelización es explicar el comportamiento de una variable a través de los errores al estimar el valor de la variable en los períodos anteriores, lo que da lugar a los modelos de medias móviles (Leandro, 2008).

Un modelo MA viene dado por la expresión:

$$Y_t = \mu + u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \cdots + \theta_q u_{t-q}$$

Donde:

- Y_t es la variable dependiente.
- $\theta_1, \dots, \theta_q$ representan los parámetros especificados por el modelo.
- u_t es el término de error.

Este tipo de modelos tiene como objetivo corregir errores cometidos en la estimación de la variable en los períodos anteriores.

3. Modelos ARMA

Los modelos $ARMA$ son modelos mixtos que incluyen tanto componentes autorregresivos como de medias móviles. Un modelo $ARMA(p,q)$ es estacionario si su parte autorregresiva es estacionaria e invertible si su componente de medias móviles es invertible (Yrigoyen 2010).

La forma general de un modelo ARMA(p,q) es:

$$Y_t = \mu + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + u_t + \theta_1 u_{t-1} + \cdots + \theta_q u_{t-q}$$

- Y_t es la variable dependiente.
- $\phi_1, \dots, \phi_p$ son los coeficientes autorregresivos.
- $\theta_1, \dots, \theta_q$ son los coeficientes de medias móviles.

En estos modelos, se asume que el término de error es ruido blanco.

“El ruido blanco surge con el término de error de los modelos cuando cumplen las tres hipótesis fundamentales: media nula, varianza constante, covarianza nula” (Arce Mahía, 2003).

Un modelo ARMA es un modelo lineal. Esto significa que la variable que define la serie temporal depende de una constante, linealmente de valores pasados de la misma variable y linealmente de una ponderación de errores de ajuste realizados en el pasado (Cuyare, 2012).

A la dependencia de la serie temporal con los valores pasados de la misma serie temporal se le denomina componente autorregresiva del modelo (AR). El número de retrasos de la serie temporal que se introducen en el modelo se denomina orden autorregresivo del modelo y se denota mediante la letra p. La palabra autorregresivo viene de que se modela este comportamiento como una regresión lineal múltiple (regresivo) con valores propios de la misma serie temporal (auto) retrasados un periodo de muestreo t (Cuyare, 2012). Siguiendo un desarrollo paralelo al anterior, se denomina componente de media móvil de un modelo ARMA a la dependencia de la serie temporal con valores pasados de los errores (MA). El número de errores pasados que se introducen en el modelo se llama orden de media móvil, y se nota con la letra q (Cuyare, 2012).

2.3.2. Modelos lineales no Estacionarios

1. Modelos ARIMA

Parte de considerar que el valor observado de una serie en un momento de tiempo determinado t, es una realización de una variable aleatoria yt definida en dicho momento de tiempo, por lo tanto, una serie de t datos es una muestra de un vector de t variables aleatorias ordenadas en el tiempo al que denominamos proceso estocástico (Leandro, 2008).

La fórmula general de un modelo ARIMA es:

$$Y_t^{(d)} = \mu + \phi_1 Y_{t-1}^{(d)} + \cdots + \phi_p Y_{t-p}^{(d)} + \theta_1 \varepsilon_{t-1}^{(d)} + \cdots + \theta_q \varepsilon_{t-q}^{(d)} + \varepsilon_t^{(d)}$$

Donde:

- $Y_t^{(d)}$ es la serie de las diferencias de orden d,

- $\phi_1, \dots, \phi_p$ son los parámetros autorregresivos,
- $\theta_1, \dots, \theta_q$ son los parámetros de medias móviles,
- $\varepsilon_t^{(d)}$ es la serie de los errores cometidos en la serie anterior.

Los modelos ARIMA son modelos paramétricos que tratan de obtener la representación de la serie en términos de la interrelación temporal de sus elementos. Este tipo de modelos, que caracterizan las series como sumas o diferencias ponderadas de variables aleatorias, fue propuesto por Yule y Slutsky en la década de los 20. Estos modelos constituyen la base de los procesos de medias móviles y autorregresivos que han tenido un gran desarrollo a partir de la publicación en 1970 del libro de Box-Jenkins sobre modelos ARIMA (Gonzalez 2009).

Ventajas del Modelo ARIMA

Los resultados del modelo son más eficientes y contienen mayor poder explicativo. El modelo realiza predicciones debido al nivel de incertidumbre que presenta por el desconocimiento de las variables en el futuro, lo que genera que los resultados sean más eficientes y tengan mayor poder explicativo. El modelo se utiliza para predicciones a mediano plazo de a 5 años (Ríos, 2008).

Estos modelos se destacan porque con un número reducido de parámetros permiten explicar la estructura de correlación que domina a una serie. Existen varios métodos de estimación de los parámetros de un modelo ARMA, los métodos tradicionales de estimación, mínimos cuadrados ordinario y máxima verosimilitud, por lo general, no se pueden utilizar en forma exacta, en especial cuando el modelo contiene términos promedio móviles porque los errores no son lineales en los parámetros. Por ello, se utilizan métodos interactivos, en especial respecto a que la distribución es la misma normal. Sin embargo, existen grandes diferencias para muestras finitas. Los modelos ARIMA, por lo general predicen bien para horizontes de tiempo (h) fuera de la muestra cortos y medios. El desempeño de los pronósticos de distintos modelos puede variar según sea la amplitud de dicho horizonte (Blaconá, 2015).

Características del Modelo ARIMA

Algunas de las características más importantes del modelo son: solamente se considera el modelo de la serie de tiempo en el pasado debido a que no toma en cuenta la información de variables causales, es un procedimiento complejo de predicción de la variable, emplea el dato más reciente como valor inicial, permite realizar varias pruebas para escoger el modelo más adecuado, examina errores recientes de pronósticos para escoger el ajuste correcto para periodos futuros, por último la metodología Box-Jenkins se ajusta a predicciones de mediano y largo plazo y extrae mayor información de las series de tiempo en comparación con otros métodos. (Ríos, 2008)

Correcta Identificación del Modelo ARIMA

“Determinar el orden de integración de la serie utilizando herramientas como el correlograma y tests de raíz unitaria. Es importante conocer que los tests de raíz unitaria tienen baja potencia ante posiciones de difícil discriminación” (Ríos, 2008). “Determinar el orden de los componentes de promedio móvil y autorregresivos del modelo. Generalmente el momento de la selección correcta no será clara, es recomendable tratar varias formulaciones guiándose por el conocimiento adquirido sobre el tema de estudio” (Ríos, 2008). Estimar los diferentes modelos construidos. No se toman en cuenta los resultados de modelos que arrojan coeficientes no significativos, un modelo aceptado tendrá un buen ajuste con coeficientes de valor cercanos a la unidad y el resultado de los residuos se comportarán como ruido blanco. (Ríos, 2008)

Estacionariedad

Otra condición de gran importancia para lograr un buen modelo ARIMA es que la serie sea estacionaria. Asumir que una serie sea estacionaria nos permite desarrollar un marco de trabajo bastante simple y usar herramientas estadísticas de muestreo de gran potencia. Así, si la media de un proceso es constante, podremos usar n observaciones para estimarla, mientras que sería mucho más complicado si la media no fuese estacionaria. (Cuyare, 2012) “Los residuos son ruido blanco, esta proposición es muy importante a la hora de verificar el modelo ARIMA, una vez que se han realizado las etapas de identificación y ajuste” (Cuyare, 2012).

Heteroscedasticidad

Según el autor (Jeffrey, 2006), la varianza del error no observable, u condicionada a las variables explicativas, es constante. La homocedasticidad deja de cumplirse cuando la varianza del error no observable cambia entre los diferentes segmentos de la población, determinados por los diferentes valores de las variables explicativas. (Gujarati Porter, 2010):

La heteroscedasticidad también surge por la presencia de datos atípicos o aberrantes, una observación atípica es la que es muy diferente (muy pequeña o muy grande) en relación con las demás observaciones en la muestra. La inclusión o exclusión de una observación de este tipo, en especial si el tamaño de la muestra es pequeño, puede alterar sustancialmente los resultados del análisis de regresión.

2. Modelos SARIMA

El modelo SARIMA (Seasonal AutoRegressive Integrated Moving Average) es una extensión del modelo ARIMA que incorpora componentes estacionales. Este modelo se utiliza para analizar y predecir series temporales que presentan tanto patrones no estacionales como estacionales.

El modelo se denota como:

$$SARIMA(p, d, q)(P, D, Q)_s$$

donde:

- p : Orden del componente autorregresivo (AR) no estacional.

- d : Grado de diferenciación no estacional.
- q : Orden del componente de media móvil (MA) no estacional.
- P : Orden del componente autorregresivo estacional (AR).
- D : Grado de diferenciación estacional.
- Q : Orden del componente de media móvil estacional (MA).
- s : Periodicidad o longitud del ciclo estacional (por ejemplo, $s = 12$ para un patrón anual con datos mensuales).

Fórmula general del modelo SARIMA

$$\Phi_P(B^s) \cdot \phi_p(B) \cdot (1 - B)^d \cdot (1 - B^s)^D Y_t = \Theta_Q(B^s) \cdot \theta_q(B) \cdot \epsilon_t$$

Donde:

- Y_t es el valor de la serie en el tiempo t .
- B es el operador de rezagos (lag operator), donde $BY_t = Y_{t-1}$.
- $\phi_p(B)$ es el polinomio autorregresivo de orden p para la parte no estacional.
- $\Phi_P(B^s)$ es el polinomio autorregresivo estacional de orden P .
- $\theta_q(B)$ es el polinomio de media móvil de orden q para la parte no estacional.
- $\Theta_Q(B^s)$ es el polinomio de media móvil estacional de orden Q .
- ϵ_t es el término de error en el tiempo t , que se asume como ruido blanco.

Componentes

- Diferenciación no estacional: $(1 - B)^d$.
- Diferenciación estacional: $(1 - B^s)^D$.
- Componentes AR y MA no estacionales: $\phi_p(B)$ y $\theta_q(B)$.
- Componentes AR y MA estacionales: $\Phi_P(B^s)$ y $\Theta_Q(B^s)$.

2.4. Metodología de Holt-Winters

El método Holt-Winters, también conocido como suavización exponencial triple, es una técnica ampliamente utilizada para el pronóstico de series temporales. Este método es particularmente útil cuando los datos muestran tanto tendencia como estacionalidad. Fue desarrollado por Charles Holt en 1957 y refinado por Peter Winters en 1960.

Existen dos variantes principales del método Holt-Winters: aditiva y multiplicativa, dependiendo de la naturaleza de la estacionalidad (constante o proporcional). Este método posee los siguientes componentes:

- **Nivel (a_t):** Representa el valor promedio de la serie en el tiempo t . Se estima utilizando la suavización exponencial del último nivel, ajustado por la tendencia y la estacionalidad.
- **Tendencia (b_t):** Captura la tasa de cambio del nivel en el tiempo t . Se estima utilizando la suavización exponencial de la última tendencia, ajustada por la tendencia anterior y la estacionalidad.
- **Estacionalidad (s_t):** Representa los efectos estacionales que se repiten en intervalos regulares. Dependiendo de si la estacionalidad es aditiva o multiplicativa, se estima utilizando la suavización exponencial de la última estacionalidad, ajustada por el nivel y la tendencia.

Estos componentes se actualizan y suavizan iterativamente utilizando ecuaciones específicas que dependen de los parámetros de suavización (α , β y γ), los cuales controlan la velocidad de adaptación de cada componente a los datos observados. La elección entre el modelo aditivo y el multiplicativo depende de cómo varíe la estacionalidad con respecto al nivel de la serie temporal.

2.4.1. Holt-Winters aditivo

Para una serie de tiempo con tendencia, y una estación constante, se establecen las siguientes ecuaciones de actualización de sus componentes:

- **Pronóstico:**

$$\hat{Z}_{t+h|t} = a_t + hb_t + s_{t-m+h(k+1)} \quad (19)$$

- **Nivel:**

$$a_t = \alpha(Z_t - s_{t-m}) + (1 - \alpha)(a_{t-1} + b_{t-1}) \quad (20)$$

- **Tendencia:**

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1} \quad (21)$$

- **Estacionalidad:**

$$s_t = \gamma(Z_t - a_t - hb_t) + (1 - \gamma)s_{t-m} \quad (22)$$

En esta expresión, la variable " k " corresponde a la parte entera de la ecuación (18), asegurando así que las estimaciones de los índices estacionales empleadas en el proceso de pronóstico estén fundamentadas en los datos del último año de la muestra.

En la ecuación (19), se observa un promedio ponderado entre la observación ajustada estacionalmente ($Z_t - s_{t-m}$) y el pronóstico estacional ($a_{t-1} + b_{t-1}$) para el tiempo t . La ecuación (20) es idéntica al método lineal de Holt. En la ecuación (21), se muestra un promedio ponderado entre la variación del nivel ($a_t - a_{t-1}$) y el índice estacional correspondiente al mismo mes de la temporada del año anterior (es decir, posiciones de tiempo atrás).

2.4.2. Holt-Winters multiplicativo

Adecuado cuando la serie tiene una tendencia, al menos localmente, y un patrón estacional creciente. Las ecuaciones de actualización son:

■ **Pronóstico:**

$$\hat{Z}_{t+h|t} = (a_t + hb_t)s_{t-m+h(k+1)} \quad (23)$$

■ **Nivel:**

$$a_t = \alpha \left(\frac{Z_t}{s_{t-m}} \right) + (1 - \alpha)(a_{t-1} + b_{t-1}) \quad (24)$$

■ **Tendencia:**

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1} \quad (25)$$

■ **Estacionalidad:**

$$s_t = \gamma \left(\frac{Z_t}{a_t + hb_t} \right) + (1 - \gamma)s_{t-m} \quad (26)$$

2.4.3. Estimación de α , β y γ e indicadores de error del modelo

En el estudio realizado por Hudson y Cohen (2016), se menciona que los coeficientes de ponderación α , β y γ se estiman inicialmente estableciendo valores iniciales y luego se ajustan mediante un proceso de optimización iterativo para lograr un ajuste adecuado. Comúnmente, se utiliza la minimización del Error Cuadrático Medio (MSE) o el Error Estándar de Estimación (6) como método de optimización. Estos indicadores se utilizan para comparar la efectividad del modelo utilizado, como se describe en el estudio de Yang et al. (2017). La precisión de predicción es un criterio de gran importancia para evaluar la validez del modelo predictivo.

2.5. Métricas de desempeño

2.5.1. Prueba Dickey-Fuller

En econometría, una prueba de Dickey-Fuller aumentada (ADF) se utiliza para evaluar la presencia de raíces unitarias en una muestra de una serie de tiempo. Esta prueba es una versión ampliada de la prueba Dickey-Fuller para un conjunto más amplio de modelos de series de tiempo. La estadística ADF, utilizada en la prueba, es un número negativo. Cuanto más negativo es, más fuerte es el rechazo de la hipótesis nula, lo que indica la presencia de una raíz unitaria. El modelo general es:

$$y_t = \mu + \sigma y_{t-1} + \epsilon_t$$

Donde:

- μ = Parámetros
- σ = Parámetros
- y_{t-1} = Proceso estacionario

- $\epsilon_t =$ Ruido blanco

Ruido Blanco

Según Manterola (2005), el ruido blanco es una señal aleatoria con ancho de banda infinito, es decir, que contiene todas las frecuencias. En otras palabras, el ruido blanco es una sucesión de variables aleatorias con esperanza nula, varianza constante y covarianzas nulas para distintos valores de t .

$$\epsilon_t = RB(0, \sigma^2)$$

El ruido blanco es una sucesión de variables aleatorias o procesos estocásticos, con una esperanza o media cero y una varianza constante e independiente de cualquier valor t (covarianza nula) (Antunez 2011).

2.5.2. Criterios de información

Criterio de Akaike

El criterio de información de Akaike (AIC) es una medida de la calidad relativa de un modelo estadístico, para un conjunto dado de datos. Como tal, el AIC proporciona un medio para la selección del modelo (Garcia 2014).

El cálculo del AIC se realiza a partir de la siguiente expresión:

$$AIC = -2 \ln(\text{max. verosimilitud}) + 2(\text{parámetros independientes ajustados})$$

El criterio de información de Akaike establece que cuanto más bajo es su valor, mejor es el modelo.

Criterio de Schwartz

El criterio de Schwarz (BIC) es un criterio para la selección de modelos entre un conjunto finito de modelos. Se caracteriza por ser una función de la probabilidad y el número de observaciones (Garcia 2014).

$$BIC = x^2 + k \cdot \ln(n)$$

De la misma forma, cuanto menor es el valor de este criterio, mejor será el modelo.

2.5.3. Estadístico Durbin-Watson

Es una estadística de prueba que se utiliza para detectar la presencia de autocorrelación en los residuos. Se identifica con la letra d y se calcula al determinar los residuos para cada observación:

$$d = \frac{\sum_{t=2}^T (e_t - e_{t-1})^2}{\sum_{t=1}^T e_t^2}$$

Donde:

- e_t = el residual asociado a la observación en el tiempo t ,
- T = el número de observaciones.

El valor del estadístico varía de 0 a 4, y es de 2 cuando no hay autocorrelación entre los residuos. Cuando el valor de d se acerca a 0, indica una autocorrelación positiva. Los valores mayores que 2 indican una autocorrelación negativa (Palomino 2016).

2.5.4. Error Absoluto Medio (MAE)

Se define como la media de los errores absolutos de predicción, dado por la ecuación (26):

$$MAE = e_{MAE} = \frac{1}{T} \sum_{t=1}^T |Z_t - \hat{Z}_t| \quad (27)$$

2.5.5. Raíz del Error Cuadrático Medio (RMSE)

Se define como la raíz cuadrada del error cuadrático medio, calculado como por la ecuación (28):

$$MSE = \frac{1}{T} \sum_{t=1}^T (Z_t - \hat{Z}_t)^2 \quad (28)$$

$$RMSE = e_{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (Z_t - \hat{Z}_t)^2} \quad (29)$$

2.5.6. Error Porcentual Absoluto Medio (MAPE)

Se define como el error absoluto medio expresado como porcentaje, dado por la ecuación (29):

$$MAPE = e_{MAPE} = \frac{1}{T} \sum_{t=1}^T \left| \frac{Z_t - \hat{Z}_t}{Z_t} \right| \quad (30)$$

NOTA: El valor ideal de estas métricas será 0, lo que indicará que no hay error de predicción.

3. MATERIALES, MÉTODOS Y PROCEDIMIENTOS

3.1. Tipo, nivel y diseño de la investigación

3.1.1. Tipo de investigación

Este estudio se clasifica como una investigación aplicada, que, como señala Murillo (2008), también es conocida como investigación práctica o empírica”. Este tipo de investigación se enfoca en la aplicación de conocimientos ya adquiridos y en la generación de nuevos saberes a través de la práctica organizada y sistemática. En la investigación aplicada, el conocimiento se implementa en contextos reales y se adquieren nuevos aprendizajes mediante el proceso de sistematización, con el propósito de comprender y mejorar la realidad práctica a través de métodos científicos rigurosos.

3.1.2. Nivel de investigación

En esta investigación, se adopta un enfoque explicativo, que, según Arias (2011), busca comprender las causas de los fenómenos a través de la identificación de relaciones de causa y efecto. Como señala Schwarz (2017), este nivel de investigación permite una comprensión integral del problema, ofreciendo una base sólida para explorar y analizar los factores que subyacen a los hechos estudiados.

3.1.3. Diseño de la investigación

El diseño de esta investigación será de naturaleza no experimental. De acuerdo con Kerlinger (2002), esto implica que no será posible manipular las variables de estudio ni asignar aleatoriamente a los sujetos o condiciones. En este caso, se adoptará un diseño longitudinal, que permite la recopilación y el análisis de datos a lo largo del tiempo para estudiar la evolución de una variable o fenómeno en un período específico. Este enfoque facilitará la observación de tendencias y cambios en el comportamiento del Índice de Precios al Consumidor (IPC) en el sector transporte de Lima Metropolitana, ofreciendo así una comprensión más profunda de las dinámicas que afectan este indicador a lo largo del tiempo.

3.1.4. Población y muestra

La población de estudio abarca los índices de precios al consumidor (IPC) de los servicios de transporte no transables en Lima Metropolitana, con datos mensuales desde febrero de 2001 hasta agosto de 2024.

3.1.5. Técnicas de recolección de datos

La recolección de datos se llevó a cabo mediante la recopilación de información secundaria disponible en la página web del Banco Central de Reserva del Perú (BCRP). La base de datos se puede consultar en el siguiente enlace: BCRP - IPC Servicios de Transporte No Transables: <https://estadisticas.bcrp.gob.pe/estadisticas/series/mensuales/resultados/PN01377PM/html>. El dataset consta de 355 observaciones correspondientes a la variación porcentual mensual del IPC.

3.1.6. Descripción de la variable

La variable de estudio es la variación porcentual del índice de precios al consumidor en servicios de transporte no transables en Lima Metropolitana. Es una variable cuantitativa que mide la fluctuación mensual de los precios en dicho sector.

3.1.7. Herramientas y Software

Se utilizó el software R Studio y Excel para el tratamiento de datos y la implementación de los modelos Holt-Winters y SARIMA, aplicando sus respectivos métodos para el pronóstico de series temporales.

3.2. Procedimiento de análisis

3.2.1. Metodología de SARIMA


A continuación, se describen las fases de la metodología:

1. **Identificación del modelo:** En esta fase, se analizan los gráficos de la serie temporal y las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) para detectar indicios de tendencias y patrones estacionales en los datos. Si la serie no es estacionaria, es decir, si muestra una tendencia o variabilidad que cambia con el tiempo, se aplican diferencias (diferenciación) para eliminar estos patrones no estacionarios. Este proceso busca transformar la serie para hacerla estable en media y varianza, facilitando el análisis de patrones repetitivos. La ACF y la PACF de la serie diferenciada se analizan para determinar el orden potencial del modelo, identificando los parámetros p y q adecuados para los componentes autorregresivo (AR) y de media móvil (MA), respectivamente.
2. **Estimación de parámetros:** Una vez identificado el orden del modelo, se procede a la estimación de los parámetros del modelo, incluyendo los coeficientes autorregresivos (AR) y de media móvil (MA). La estimación se lleva a cabo mediante algoritmos de optimización, que buscan maximizar la función de verosimilitud para los datos de la serie temporal. Además, se analizan los valores estimados para evaluar la significancia estadística de los coeficientes, lo cual ayuda a determinar si los términos incluidos en el modelo son relevantes. El análisis de los residuos es clave en esta fase, ya que permite comprobar si el modelo está capturando adecuadamente la estructura de los datos sin dejar patrones de dependencia no explicados.
3. **Verificación y diagnóstico del modelo:** Después de la estimación, es fundamental verificar si el modelo ajustado representa adecuadamente los datos de la serie temporal. En esta etapa, se evalúan los residuos para confirmar que se comportan como ruido blanco, es decir, que son independientes, siguen una distribución normal con media cero, covarianza nula y varianza constante. Un buen ajuste del modelo se refleja en residuos que cumplen con estas propiedades. Si los residuos no cumplen estos criterios, puede ser necesario ajustar o modificar el modelo, probando diferentes órdenes para los términos AR, MA.
4. **Pronóstico y evaluación:** Una vez que el modelo ha sido verificado y validado, se utiliza para realizar pronósticos. En esta fase, los pronósticos generados por el

modelo se comparan con los datos reales en un conjunto de prueba, evaluando su precisión mediante métricas como el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE). Estas métricas ayudan a cuantificar la precisión del modelo y a identificar cualquier ajuste adicional necesario para mejorar su capacidad predictiva.

El procedimiento descrito para el modelo se resume en el esquema que se muestra en la Figura 2.

Figura 2: Metodología de Box-Jenkins



Fuente: Adaptado de Rojas-R. et al., 2019.

3.2.2. Metodología de Holt - Winters

La metodología de suavización exponencial Holt-Winters es un enfoque robusto para el pronóstico de series temporales, que se implementa a través de un proceso sistemático que puede describirse en las siguientes fases:

1. **Selección del Tipo de Suavización:** En primer lugar, se determina si se utilizará un método aditivo o multiplicativo, dependiendo de la naturaleza de las

fluctuaciones estacionales presentes en la serie temporal.

- **Método Aditivo:** Se aplica cuando las fluctuaciones estacionales son constantes en términos absolutos, es decir, el patrón estacional se mantiene con una variación constante, independientemente del nivel de la serie.
 - **Método Multiplicativo:** Se prefiere este enfoque cuando las fluctuaciones estacionales cambian proporcionalmente al nivel de la serie, lo que implica que la amplitud de la estacionalidad aumenta o disminuye a medida que varía el nivel de la serie.
2. **Estimación de Coeficientes Iniciales:** En esta fase, se establecen valores iniciales para los coeficientes de suavizado, que son fundamentales para la modelización:


- α (alfa): Este coeficiente controla la suavización del nivel o promedio de la serie temporal.
- β (beta): Ajusta la suavización de la tendencia observada en la serie.
- γ (gamma): Regula la suavización de la componente estacional.

Los valores iniciales pueden determinarse mediante enfoques heurísticos, basados en la experiencia previa, o a través de técnicas de optimización que buscan mejorar la precisión de las predicciones. La elección adecuada de estos parámetros es crucial, dado que impacta directamente en el ajuste del modelo a los datos históricos.

3. **Ajuste y Optimización de Coeficientes:** Los coeficientes de suavizado se optimizan a través de un proceso iterativo diseñado para minimizar el error de ajuste en los datos históricos. Las técnicas de optimización comúnmente empleadas incluyen:
- Minimización del Error Cuadrático Medio (MSE): Este método se centra en reducir el promedio de los errores al cuadrado entre los valores observados y aquellos pronosticados por el modelo.
 - Error Estándar de Estimación (SEE): Este enfoque calcula el promedio del error cuadrático en relación a los valores estimados, ofreciendo una medida de la precisión del ajuste del modelo.
4. **Predicción y Validación del Modelo:** Tras el ajuste del modelo, se generan pronósticos que son evaluados en la fase de prueba. Para verificar la precisión de las predicciones, se utilizan diversas métricas de error, tales como:
- Error Absoluto Medio (MAE): Este indicador representa el promedio de los valores absolutos de los errores, proporcionando una medida clara del error promedio en las unidades originales de la serie temporal.
 - Raíz del Error Cuadrático Medio (RMSE): Similar al MSE, pero expresado en las unidades originales, permite evaluar el tamaño promedio del error de predicción.
 - Error Porcentual Absoluto Medio (MAPE): Este método mide el error de predicción en términos porcentuales, facilitando la comparación entre diferentes series temporales o modelos.

El procedimiento descrito para el modelo de suavización exponencial Holt-Winters se resume en el esquema que se muestra en la Figura 3. Esta figura ilustra el flujo de pasos necesarios, desde la selección del tipo de suavización hasta la validación final del modelo mediante métricas de error.

Figura 3: Metodología de Holt-Winters



Fuente: Adaptado de Mejía, Eduar y Gonzales, Salomé

4. PRESENTACIÓN Y ANÁLISIS DE RESULTADOS

4.1. Análisis Exploratorio

Se realizó un análisis exploratorio de los datos, comenzando con la gráfica de la serie de tiempo del Índice de Precios al Consumidor (IPC) en transporte en Lima Metropolitana desde febrero de 2001 hasta agosto de 2024. Este análisis permitirá identificar patrones de tendencia y estacionalidad, así como variaciones en los datos a lo largo del tiempo.




Figura 4: Serie de tiempo del IPC en transporte.

La Figura 4 de la serie temporal del Índice de Precios al Consumidor (IPC) en el sector transporte de Lima Metropolitana, de 2001 a 2024, muestra la evolución de los precios en este sector y revela varios patrones.

- **Picos Pronunciados:** Se destacan picos en años como 2003, cuando el IPC superó 7.5, así como en 1999-2000 y recientemente en 2022-2023. Estos picos suelen coincidir con factores externos, como alzas en el precio del petróleo o crisis económicas que impactan el transporte.
- **Estabilidad Relativa:** En periodos como 2004-2008, el IPC se mantiene más estable, con fluctuaciones moderadas cercanas a cero. Esto podría reflejar estabilidad en costos de insumos o intervenciones de subsidio.
- **Tendencia y Ausencia de Estacionalidad:** La serie no muestra una clara tendencia ascendente o descendente, sino una fluctuación constante con picos esporádicos. Además, no se observan patrones estacionales fuertes, lo que indica que el IPC de transporte responde más a eventos externos que a ciclos estacionales.

- **Causas de Picos y Bajadas:** Los cambios extremos en el IPC suelen estar vinculados a variaciones en la regulación, cambios en los costos de combustibles, o ajustes en la oferta y demanda de transporte durante periodos de crisis. Esto sugiere que el IPC en transporte es altamente sensible a factores económicos y políticos externos.

Descripción	Valor
Número de observaciones	283
Media aritmética	0.25309
Desviación estándar	1.03725
Valor mínimo	-1.41412
Primer cuartil (Q1)	-0.18453
Mediana (Q2)	0.05861
Tercer cuartil (Q3)	0.46910
Valor máximo	8.91627

Cuadro 1: Resumen de estadísticas descriptivas de IPC Transporte

Las estadísticas descriptivas en el Cuadro 1 reflejan el comportamiento del IPC en el sector de Transporte. Con una media de 0.25 y una mediana de 0.06, se evidencia un sesgo positivo, indicando que los valores más altos tienen mayor impacto en el promedio general. La desviación estándar de 1.04 muestra una variabilidad moderada, lo que sugiere fluctuaciones regulares pero no excesivas en los precios del transporte.

El valor mínimo de -1.41 apunta a periodos de deflación, posiblemente asociados a ajustes en subsidios o disminuciones en los costos de insumos. Por otro lado, el valor máximo de 8.92 corresponde a periodos de alta inflación, probablemente impulsados por incrementos en los costos de combustible o cambios estacionales en la demanda. Los cuartiles refuerzan el sesgo positivo, ya que el 25 % de las observaciones presenta valores significativamente altos en comparación con los demás, lo cual podría deberse a eventos económicos específicos o ajustes regulatorios.

4.1.1. Suavizado de la Serie Temporal

Para realizar el suavizado de la serie, se emplearon técnicas de medias móviles centrales, calculando el promedio de bloques de cinco observaciones consecutivas. Este método permite que el valor suavizado refleje el comportamiento general de la serie en lugar de los cambios bruscos. En el periodo especificado, la serie suavizada muestra una reducción de los picos, permitiendo ver tendencias a largo plazo en el IPC del transporte.

- Desde enero de 2003 hasta mayo de 2003: En este periodo también se registraron picos pronunciados en el IPC, y el suavizado ayuda a minimizar estas fluctuaciones, mostrando una tendencia más uniforme en el gráfico.

Observaciones:

- En la gráfica, el pico más altos en el año 2003 se suaviza considerablemente, lo que permite analizar el IPC sin las distorsiones causadas por los aumentos repentinos de precios en esos años.

- El uso del suavizado expone de manera más clara los cambios estructurales en el IPC, especialmente en periodos de crisis o estabilidad relativa.




Figura 5: Comparación de la serie de tiempo original y la serie suavizada

A continuación, utilizaremos los valores obtenidos para suavizar los picos observados en ese intervalo. Gráficamente, este ajuste se representa en la figura, y será la base que utilizaremos para la construcción de los modelos.




Figura 6: Serie de tiempo suavizada del IPC en transporte.

4.1.2. Análisis mediante Gráfico de Caja y Bigotes

El gráfico de caja y bigotes facilita la visualización de la dispersión y la identificación de valores atípicos en la serie de IPC. Este análisis es útil para observar la variabilidad

intercuartílica y posibles anomalías en los datos.




Figura 7: Gráfico de caja y bigotes del IPC en transporte.

El análisis del gráfico de caja y bigotes del Índice de Precios al Consumidor (IPC) en el sector transporte en Lima Metropolitana muestra variabilidad significativa a lo largo del año. En los primeros meses (enero a marzo), el IPC presenta una dispersión menor, con valores concentrados alrededor de la media. A medida que avanza el año, especialmente hacia noviembre y diciembre, se observa un aumento en la dispersión, con una caja más amplia y varios valores atípicos fuera de los bigotes. Estos meses finales destacan por mostrar fluctuaciones inusuales en el IPC, lo cual puede estar relacionado con factores estacionales o económicos específicos. Los valores atípicos, visibles en estos meses, reflejan eventos o comportamientos erráticos, sugiriendo situaciones que podrían haber afectado el índice en esta época.

Podemos concluir que el gráfico evidencia una tendencia ascendente del IPC hacia fin de año, acompañada de mayor variabilidad y valores atípicos, proporcionando una visión clara sobre el comportamiento de este indicador y posibles anomalías en ciertos meses.

4.1.3. Evaluación de Dependencia Temporal: ACF y PACF

La evaluación de la estructura de dependencia temporal mediante los gráficos de Autocorrelación (ACF) y Autocorrelación Parcial (PACF) permite identificar patrones de correlación en el IPC.

Para analizar la estacionalidad, se examinaron los correlogramas de la Función de Autocorrelación (ACF) en la Figura 8 y la Función de Autocorrelación Parcial (PACF) en la Figura 9. La serie cuenta con 332 observaciones mensuales, por lo que inicialmente se consideró un rango de rezagos de aproximadamente $\sqrt[3]{283} \approx 16$. No obstante, para un modelado ARIMA adecuado, se recomendó ampliar el rango a 24 rezagos, considerando la periodicidad mensual de los datos.

En el análisis de Figura 8 de autocorrelación (ACF) del IPC en el sector transporte de Lima Metropolitana, la serie analizada presenta indicios de no estacionariedad, dado

que el valor de autocorrelación en el primer rezago es muy alto y disminuye gradualmente, lo cual sugiere una fuerte dependencia temporal. Esto usualmente se asocia a una tendencia a largo plazo, dado que, en series estacionarias, la autocorrelación cae rápidamente a cero después de pocos rezagos. La alta autocorrelación en los primeros rezagos respalda la existencia de una tendencia subyacente en la serie, confirmada por la lenta disminución de la ACF (Autocorrelación Funcional).

En cuanto al análisis de la autocorrelación y la estructura de rezagos, se observa una autocorrelación significativa en el primer rezago, lo que sugiere una dependencia fuerte entre observaciones consecutivas y un patrón de suavización lenta. Además, la presencia de valores de autocorrelación significativos en rezagos posteriores, sin disminuir a cero rápidamente, podría sugerir un componente estacional. Algunos rezagos específicos (como el 12 y el 24) muestran autocorrelaciones positivas y significativas, sugiriendo una posible estacionalidad anual. Esta podría reflejarse en variaciones estacionales de precios, debido a factores como fluctuaciones en el costo de combustibles o aumentos en periodos de alta demanda.




Figura 8: Correlograma del IPC en transporte

En la Figura 9, en cuanto al análisis de estacionariedad y tendencia en la serie sugiere que esta no es estacionaria en su forma actual, dado que el PACF muestra autocorrelaciones significativas solo en los primeros rezagos y luego cae rápidamente. Esto sugiere una posible dependencia de corto plazo, pero no asegura estacionariedad, indicando la presencia de una tendencia subyacente o estacionalidad en la serie. A pesar de la rápida caída en el PACF, la significativa autocorrelación en el primer rezago señala una posible tendencia de fondo que podría requerir diferenciación para estabilizar la serie.

En cuanto a la estructura de rezagos, el primer rezago significativo sugiere que un modelo AR de bajo orden podría capturar la dependencia inmediata de la serie. La progresiva reducción de autocorrelaciones en los rezagos posteriores sugiere que un modelo AR de primer o segundo orden podría ser adecuado. Además, la autocorrelación significativa en rezagos específicos como el 12 y el 24 sugiere una estacionalidad anual, indicativa de ciclos que se repiten cada 12 meses, posiblemente relacionados con factores

estacionales como el precio de combustibles y la demanda en el transporte.




Figura 9: Correlograma parcial del IPC en transporte

En la Figura 10, realizamos la descomposición de la serie de tiempo para poder visualizarlo mejor:




Figura 10: Descomposición de los componentes de la serie de tiempo

El análisis de los componentes de la serie de tiempo para el IPC en transporte revela patrones claros en sus fluctuaciones y tendencias:

En la serie observada, se destacan fluctuaciones regulares con picos que reflejan

posibles cambios de precios. Hacia el final, la amplitud de estas fluctuaciones parece aumentar, sugiriendo variabilidad reciente en los costos de transporte. La tendencia muestra un incremento gradual entre 2001 y 2007, seguido de estabilización y una ligera disminución hasta 2015. Desde 2015, la tendencia se eleva notablemente, alcanzando un máximo en 2021, posiblemente influido por eventos económicos o la pandemia. A partir de 2023-2024, se vislumbra una caída, sugiriendo un ajuste a la baja.

El componente estacional exhibe un patrón repetitivo anual, señalando que el IPC en transporte responde de manera cíclica, posiblemente relacionado con temporadas específicas, como vacaciones o variaciones en la demanda de combustible. Este patrón es útil para prever cambios regulares en el sector.

Finalmente, el componente aleatorio muestra baja variabilidad general, sugiriendo que los componentes de tendencia y estacionalidad explican la mayoría de las variaciones. Los picos inusuales pueden asociarse a crisis externas, como la pandemia, mientras que hacia el final de la serie, esta variabilidad aleatoria disminuye, indicando mayor estabilidad en el sector.

4.1.4. Verificación de Estacionariedad

La verificación de la estacionariedad de la serie es fundamental en la modelización. Para ello, se aplican pruebas de raíz unitaria, como Dickey-Fuller, observando la media y varianza constantes a través del tiempo en la serie del IPC.

La ecuación para la prueba de Dickey-Fuller es:

$$\Delta Y_t = \alpha Y_{t-1} + \beta + \delta t + \epsilon_t \quad (2)$$

Planteamos nuestras hipótesis:

H_0 : La serie tiene una raíz unitaria, es no estacionaria.

H_1 : La serie no tiene una raíz unitaria, es estacionaria.

En el Cuadro 2, se observaron 6 rezagos y se aplicó la Prueba ADF (Dickey-Fuller Aumentada), cuyo resultado mostró un p-valor menor que 0.05. Esto indica que podemos rechazar la hipótesis nula y concluir que la serie es estacionaria.

Descripción	Valor
Dickey-Fuller	-5.2832
Orden de rezagos	6
p-valor	0.01

Cuadro 2: Resultados del Test de Dickey-Fuller

4.1.5. Transformación Logarítmica de la Serie

Ajuste de Valores Negativos y Aplicación de la Transformación Logarítmica: Se aplicó un ajuste sumando una constante mayor que el valor absoluto mínimo de la serie. Esta operación generó la serie *ipc.ts_adjusted*, permitiendo así la aplicación de la transformación logarítmica sin problemas. La transformación logarítmica, aplicada

sobre *ipc_ts_adjusted* y almacenada en *ipc_log*, contribuye a estabilizar la varianza y reduce la influencia de valores extremos, haciéndola más adecuada para el análisis y modelado.

Para evaluar visualmente los efectos del ajuste y la transformación logarítmica, se realizaron dos gráficos:




Figura 11: Comparación de la serie original y la serie transformada

Serie Original Ajustada: La primera gráfica muestra la serie de tiempo ajustada en función del tiempo. Este gráfico se presenta en color azul y permite observar cómo el ajuste de valores negativos transforma la serie, manteniendo su estructura estacional y tendencias generales. Este paso es crucial para preparar la serie para análisis subsecuentes.

Serie Transformada Logarítmica: La segunda gráfica representa la serie transformada logarítmicamente, mostrada en color verde. La transformación logarítmica tiene un efecto suavizante sobre las variaciones de la serie, especialmente en las oscilaciones de gran amplitud. Esta visualización facilita la observación de patrones subyacentes y es un paso importante en la preparación de datos para modelos que asumen homocedasticidad (varianza constante).

Estas representaciones gráficas brindan una visión clara de cómo los ajustes y transformaciones aplicados afectan la estructura de la serie de tiempo, preparándola para el modelado y análisis predictivo

4.2. Modelamiento SARIMA

En base a la metodología de Box-Jenkins, seleccionamos cinco modelos, resultado de numerosas pruebas, obteniéndose los parámetros significativos para tales modelos:

Modelo	Parámetro	Estimación	Error Estándar	P-valor
$SARIMA(0,1,1)(0,1,1)_{12}$	θ_1	-0.7054	0.0681	$< 2,2e - 16$
	Θ_1	-0.8096	0.0422	$< 2,2e - 16$
$SARIMA(1,0,1)(1,0,1)_{12}$	ϕ_1	0.6959	0.0955	$3,159e - 13$
	θ_1	-0.4369	0.1154	0,0001527
	Φ_1	0.9871	0.0075	$< 2,2e - 16$
	Θ_1	-0.7980	0.0450	$< 2,2e - 16$
	μ	0.9522	0.1115	$< 2,2e - 16$
$SARIMA(2,0,0)(0,1,1)_{12}$	Φ_1	0.2623	0.0616	$2,053e - 05$
	Φ_2	0.1721	0.0613	0,005027
	Θ_1	-0.8115	0.0423	$< 2,2e - 16$
$SARIMA(1,0,1)(0,1,1)_{12}$	Φ_1	0.6943	0.0961	$5,087e - 13$
	θ_1	-0.4186	0.1164	0,000325
	Θ_1	-0.8056	0.0418	$< 2,2e - 16$
$SARIMA(0,0,1)(1,1,1)_{12}$	θ_1	0.2610	0.0539	$1,297e - 06$
	Φ_1	-0.2157	0.0841	0,01032
	Θ_1	-0.7016	0.0684	$< 2,2e - 16$

Cuadro 3: Resultados de los modelos SARIMA

Después de la estimación de los parámetros, aplicaremos la prueba de Ljung-Box test de autocorrelación para verificar si los residuos de los modelos propuestos tienen una distribución de ruido blanco (es decir, si no hay autocorrelación en los residuos).

La prueba de Ljung-Box se puede definir de la siguiente manera:

H_0 : Los datos se distribuyen de forma independiente.

H_1 : Los datos no se distribuyen de forma independiente.

Modelos	P-valor
$SARIMA(0,1,1)(0,1,1)_{12}$	0.0916
$SARIMA(1,0,1)(1,0,1)_{12}$	0.6568
$SARIMA(2,0,0)(0,1,1)_{12}$	0.5314
$SARIMA(1,0,1)(0,1,1)_{12}$	0.6603
$SARIMA(0,0,1)(1,1,1)_{12}$	0.0542

Cuadro 4: Resultados del Test de Ljung-Box

En el Cuadro 4, se presentan los valores de p obtenidos del Test de Ljung-Box para cada modelo. En este caso, todos los valores de p son superiores al umbral de significancia comúnmente utilizado de 0.05. Esto nos lleva a rechazar la hipótesis nula (H_0) en todos los modelos, lo que indica que los residuos de los modelos son ruido blanco, es decir, no presentan autocorrelación significativa.

Este resultado se confirma mediante el análisis de los residuales, en el cual se observa que la autocorrelación de los residuos es mínima o inexistente, lo que implica que no

existe patrón predecible en los errores del modelo y que estos pueden considerarse como ruido blanco. Esto valida que los modelos seleccionados están bien especificados y que las predicciones obtenidas serán robustas, sin patrones no capturados por el modelo.




Figura 12: Residuales del modelo SARIMA(0,1,1)(0,1,1)₁₂




Figura 13: Residuales del modelo SARIMA(1,0,1)(1,0,1)₁₂




Figura 14: Residuales del modelo SARIMA(2,0,0)(0,1,1)₁₂





Figura 15: Residuales del modelo SARIMA(1,0,1)(0,1,1)₁₂

Figura 16: Residuales del modelo SARIMA(0,0,1)(1,1,1)₁₂

Según las Figuras 12, 13, 14, 15 y 16, se observa que los errores se distribuyen de forma aleatoria, lo que sugiere que presentan una varianza constante. Las funciones de autocorrelación de los modelos no resultan significativas. El gráfico Q-Q de los residuos muestra una distribución cercana a la normal.

Posteriormente, se realizaron pronósticos y se aplicaron métricas de error, como el MAE, RMSE y MAPE, para evaluar la precisión de cada modelo SARIMA. Los resultados de estas métricas para cada modelo se presentan en el Cuadro 5:

Modelo	MAE	MAPE	RMSE
SARIMA(0,1,1)(0,1,1) ₁₂	0.1165	12.67 %	0.1504
SARIMA(1,0,1)(1,0,1) ₁₂	0.1167	12.64 %	0.1410
SARIMA(2,0,1)(0,1,1) ₁₂	0.1199	13.04 %	0.1471
SARIMA(1,0,1)(0,1,1) ₁₂	0.1205	13.09 %	0.1477
SARIMA(0,0,1)(1,1,1) ₁₂	0.1440	15.59 %	0.1687

Cuadro 5: Resumen de Modelos SARIMA y sus Medidas de Error

Los resultados obtenidos muestran que el modelo SARIMA(1,0,1)(1,0,1)₁₂ es el más robusto en términos de rendimiento general, ya que presenta el menor RMSE (0.1410) y el menor MAPE (12.64 %), lo que indica una excelente capacidad para manejar errores grandes y proporcionar predicciones precisas en términos relativos.

Después de validar los residuos de los modelos y determinar cuál es el mejor modelo para pronosticar el IPC en el sector transporte de Lima Metropolitana para el periodo de septiembre a diciembre de 2024, se presentarán los resultados del pronóstico en el Cuadro 6, y su correspondiente gráfico en la Figura 17.

Fecha	Pronóstico	Lower80	Upper80	Lower95	Upper95
2024-09	0.02766	-0.46068	0.63809	-0.67832	1.02078
2024-10	0.49421	-0.10451	1.24813	-0.36981	1.72341
2024-11	0.12208	-0.40703	0.79068	-0.64085	1.21327
2024-12	1.83734	0.94477	2.96708	0.55085	3.68203

Cuadro 6: Pronósticos para los meses de septiembre-diciembre de 2024

Los pronósticos del modelo SARIMA para septiembre-diciembre 2024 presentan valores crecientes y una notable expansión en los intervalos de confianza. Los valores esperados muestran un aumento significativo en diciembre (1.8373), sugiriendo un posible componente estacional o un cambio estructural en la serie temporal. Los intervalos de confianza, especialmente en diciembre, son amplios, reflejando una creciente incertidumbre en el horizonte de pronóstico. La creciente amplitud de estos intervalos con el tiempo sugiere una incertidumbre acumulativa, lo cual es común en proyecciones a largo plazo.




Figura 17: Vista gráfica de los pronósticos del modelo SARIMA

4.3. Modelamiento Holt-Winters

Con base en la Figura 6, que ilustra la serie temporal del Índice de Precios al Consumidor (IPC) en el sector Transporte para Lima Metropolitana desde febrero de 2001 hasta enero de 2024, se optó por aplicar un modelo Holt-Winters Aditivo. Esta decisión se fundamenta en diversas características identificadas en la serie.

Primero, según la Figura 10 de la descomposición de la serie, la tendencia presenta fluctuaciones significativas a lo largo del tiempo, pero carece de cambios abruptos que justifiquen un enfoque multiplicativo. Esto sugiere que el comportamiento general de la serie puede ser adecuadamente modelado mediante un enfoque aditivo.

Además, se identifica un patrón estacional claramente definido y consistente, con incrementos y decrementos que se mantienen relativamente constantes. Este patrón refuerza la noción de que la estacionalidad actúa como un efecto aditivo sobre la tendencia, sin variar proporcionalmente al nivel general de la serie.

Las fluctuaciones estacionales muestran una magnitud similar a lo largo de toda la serie temporal, lo que indica que las interacciones entre los componentes (tendencia, estacionalidad y ruido) son mejor descritas por un modelo aditivo. Por lo tanto, el enfoque de Holt-Winters Aditivo se considera el más adecuado para capturar la dinámica observada en esta serie temporal del IPC en el sector Transporte.

Para empezar con el modelamiento, comenzaremos tomando algunos valores iniciales supuestos para el modelo que posteriormente iremos ajustando con iteraciones para obtener los valores óptimos:

Parámetros	Valor
α	0.3
β	0.1
γ	0.4

Cuadro 7: Valores iniciales

Con estos valores iniciales de los parámetros, procederemos a realizar los primeros pronósticos basados en los datos observados. Evaluaremos si los parámetros iniciales son adecuados o si necesitan algún tipo de ajuste.

IPC.Transporte								
		L	ALFA	BETA	GAMMA			
		12	0.3	0.1	0.4			
t	Yt	Lt	Tt	St	Pronóstico	Zt - Ft	(Zt - Ft) ²	MAPE
1	0.7784529			-0.087				
2	0.867878			0.002				
3	1.2115399			0.346				
4	0.5496762			-0.316				
5	0.852562			-0.013				
6	1.0038099			0.138				
7	0.7203433			-0.145				
8	0.841408			-0.024				
9	0.8609577			-0.005				
10	0.7773834			-0.088				
11	1.300276			0.435				
12	0.6248376	0.866	0.084	-0.241				
13	0.8694687	0.952	0.085	-0.085476	0.863	0.007	0.000	0.75
14	0.9269872	1.003	0.081	-0.029243	1.039	0.112	0.013	12.08
15	0.7733145	0.887	0.062	0.161806	1.430	0.657	0.432	84.97
16	0.8781497	1.023	0.069	-0.247438	0.633	0.245	0.060	27.92
17	0.9153794	1.043	0.064	-0.058837	1.078	0.163	0.027	17.81
18	1.0929972	1.061	0.060	0.095548	1.245	0.152	0.023	13.89
19	0.838098	1.080	0.055	-0.183833	0.975	0.137	0.019	16.37
20	0.7314671	1.021	0.044	-0.130509	1.111	0.379	0.144	51.83

Figura 18: Pronósticos iniciales utilizando el modelo Holt-Winters Aditivo




Figura 19: Gráfico de líneas del IPC en el sector transporte y su pronóstico

En la Figura 19 correspondiente al ajuste inicial del modelo, se observa que los resultados no se ajustan adecuadamente a los datos reales, lo que indica la necesidad de modificar los valores de los parámetros para obtener un modelo más óptimo. Los valores iniciales sirvieron como punto de partida para actualizar las fórmulas recursivas que describen el nivel, la tendencia y la estacionalidad.

Posteriormente, se calcularon los errores de pronóstico y las métricas de evaluación como MAE, RMSE y MAPE, considerando tanto los valores iniciales como los ajustes realizados. Estas métricas fueron esenciales para identificar los parámetros de suavizado óptimos, bajo las siguientes restricciones:

$$0 \leq \alpha, \beta, \gamma \leq 1$$

Con el objetivo de minimizar el MAPE, se utilizó la función *Solver* de Excel, aplicando la técnica de optimización GRG Nonlinear. Este método permitió encontrar los valores óptimos para los parámetros (α, β, γ) , logrando un ajuste más preciso a los datos observados. La configuración detallada de *Solver* utilizada para este proceso se presenta en la Figura 20.




Figura 20: Optimización de parámetros usando SOLVER

Después de minimizar el MAPE, se procedió a actualizar los parámetros de Holt-Winters correspondientes al nivel, la tendencia y la estacionalidad. En el Cuadro 8, se presentan los nuevos parámetros actualizados.

Parámetros	Valor
α	0.3627
β	0.0462
γ	0.2516

Cuadro 8: Parámetros optimizados

Se notaron cambios en los valores de los parámetros. A continuación, se llevará a cabo un análisis gráfico para determinar si estas modificaciones se traducen en una mejora en el ajuste de los datos.




Figura 21: Gráfico de líneas del IPC y su pronóstico con parámetros optimizados

Se observa una mejora significativa en el ajuste del modelo, lo que se traduce en una mayor precisión en la calidad de los pronósticos generados.

La optimización de los parámetros no solo ha permitido su actualización, sino que también ha generado una reducción significativa en los errores de predicción, resultando en mejoras en las métricas de rendimiento, específicamente en los valores de MAE, RMSE y MAPE.

Métrica	Valor
MAE	0.126
RSME	0.172
MAPE	13.91

Cuadro 9: Métricas de Error de pronósticos Holt-Winters

Tras identificar el modelo Holt-Winters más adecuado con los parámetros óptimos para pronosticar el IPC del sector transporte en Lima Metropolitana durante el periodo

de septiembre a diciembre de 2024, se expondrán los resultados del pronóstico en el Cuadro 10, acompañado de su representación gráfica en la Figura 22.

Fecha	Pronóstico
2024-09	-0.12996
2024-10	0.23704
2024-11	-0.27157
2024-12	1.61682

Cuadro 10: Pronósticos del IPC en el sector transporte

Los valores proyectados indican una variabilidad significativa, con un posible incremento hacia finales del año, que podrían estar influenciados por factores como la demanda estacional, así como el impacto de variaciones en el precio de combustibles.




Figura 22: Gráfico de los pronósticos sep-dic del 2024 con parámetros optimizados

4.4. Comparación de Modelos

Se realizó una comparación entre los modelos SARIMA y Holt-Winters utilizando métricas como MAE, RMSE y MAPE. Los resultados se presentaron en la tabla resumen mostrada en el Cuadro 11 para ambos modelos.

Modelo	MAE	MAPE	RMSE
SARIMA(1,0,1)(1,0,1) ₁₂	0.1167	12.64 %	0.1410
Holt-Winters	0.126	13.91 %	0.172

Cuadro 11: Comparación de las métricas de rendimiento de los modelos

Los resultados muestran que el modelo SARIMA destaca por obtener los valores más bajos en las métricas MAE, MAPE, y RMSE, lo que indica una mayor precisión en su capacidad predictiva en comparación con el modelo Holt-Winters.

5. CONCLUSIONES

- La evaluación comparativa entre los modelos SARIMA(1,0,1)(1,0,1)₁₂ y Holt-Winters Aditivo mediante métricas de error como MAE, RMSE y MAPE demostró que el modelo SARIMA ofrece pronósticos significativamente más precisos. En particular, el RMSE del modelo SARIMA fue aproximadamente un 18 % menor que el de Holt-Winters, evidenciando una mejor capacidad para reducir las desviaciones cuadráticas respecto a los valores reales. Además, el MAPE del modelo SARIMA alcanzó un 12.64 %, superando al modelo Holt-Winters al presentar un menor error relativo promedio. Estas diferencias, respaldadas estadísticamente, confirman que el modelo SARIMA es el más adecuado para el pronóstico del Índice de Precios al Consumidor (IPC) en el sector transporte de Lima Metropolitana durante el período evaluado.
- El análisis de la serie temporal del Índice de Precios al Consumidor (IPC) en el sector transporte reveló una marcada estacionalidad y una tendencia ascendente en los últimos años. Estas características justifican el uso de modelos con componentes estacionales y de tendencia para un pronóstico más preciso. La estacionalidad recurrente fue validada mediante el análisis de ACF y PACF, identificándose periodicidades significativas que sustentaron la elección de los modelos evaluados.
- El modelo Holt-Winters en su versión aditiva mostró un ajuste satisfactorio a los datos históricos, evidenciado por métricas de error como el error absoluto medio (MAE) y el error porcentual absoluto medio (MAPE) que reflejaron su capacidad para capturar las dinámicas de la serie en escenarios de alta estacionalidad. A lo largo del análisis, el MAPE del modelo Holt-Winters aditivo se mantuvo dentro de un rango aceptable, especialmente en los períodos con mayor variabilidad estacional. Sin embargo, presentó limitaciones al intentar capturar fluctuaciones más complejas, especialmente en los patrones no estacionales.
- El ajuste del modelo SARIMA al IPC en el sector transporte permitió capturar eficazmente tanto las fluctuaciones estacionales como las no estacionales de la serie temporal. Tras un riguroso proceso de identificación, estimación y validación, el modelo SARIMA(1,0,1)(1,0,1)₁₂ mostró ser el más adecuado, presentando métricas de error como MAE, MAPE y RMSE bastante bajas, lo que confirma su precisión en el pronóstico. Este modelo incorporó correctamente los patrones de periodicidad mensual y la dinámica histórica del IPC, cumpliendo con los supuestos de estacionariedad y ruido blanco en los residuos.

6. BIBLIOGRAFÍA

- Arias, F. G. (2011). El proyecto de investigación: Introducción a la metodología científica. Episteme.
- Antunez Irgoin, C. H. (2011). Análisis de series de tiempo. Contribuciones a la Economía, 2011(2). <http://www.eumed.net/ce/2011a/chai.html>
- Banco Central de Reserva del Perú. (s. f.). Índice de precios al consumidor Lima Metropolitana: Productos No Transables-Servicios-Servicios de Transporte. Recuperado de <https://estadisticas.bcrp.gob.pe/estadisticas/series/mensuales/resultados/PN01377PM/html>
- Blaconá, M. (2015). Breve reseña de métodos de análisis y pronósticos probabilísticos en series de tiempo. Revista de la Sociedad Argentina de Estadística.
- Cuyare, J. R. (2012, septiembre 10). SlideShare. Obtenido de Modelos ARIMA: https://es.slideshare.net/juan_churqui/modelo-arima-14236175
- De Arce, R., Mahía, R. (2003). Modelos ARIMA. Programa CITUS: Técnicas de Variables Financieras, 5.
- ESAN. (s.f.). Los desafíos actuales de la infraestructura vial en Perú: Propuestas de cierre de brechas. Observatorio de ESAN. <https://observatorio.esan.edu.pe/descargables/los-desafios-actuales-de-la-infraestructura-vial-en-peru-propuestas-de-cierre-de-brechas/>
- Forbes. (2023, diciembre 1). La inflación bajó un 0,26 % en noviembre a nivel nacional, informó el INEI. Forbes Perú. <https://forbes.pe/economia-y-finanzas/2023-12-01/la-inflacion-bajo-un-026-en-noviembre-a-nivel-nacional-informo-el-inei>
- Forbes Staff. (2023, septiembre 1). Inflación subió en agosto, pero fue más baja que en julio. Forbes Perú. <https://forbes.pe/economia-y-finanzas/2023-09-01/inflacion-subio-en-agosto-pero-fue-mas-baja-que-en-julio>
- García, M., Castellana, N. (2014). Saberes: Revista de Ciencias Económicas y Estadística. Obtenido de www.saberes.fcecon.unr.edu.ar/index.php/revista/article/view/98/262
- Hernández, J. (2005). Análisis de series temporales económicas: modelos ARIMA. España: ESIC.
- Infobae. (2022, junio 2). Inflación de Lima se ve impactada por alza de precios de combustible y pasajes de transporte público. <https://www.infobae.com/america/peru/2022/06/02/inflacion-de-lima-se-ve-impactada-por-alza-de-precios-de-combustible-y-pasajes-de-transporte-publico/>

- Instituto Nacional de Estadística e Informática (INEI). (2001). Índice de Precios al Consumidor de Lima Metropolitana: Metodología y Aplicaciones. Centro de Investigación y Desarrollo (INEI/CIDE).
- Jamis Mejía Vásquez, E., Gonzales Chávez, S. (2019). Predicción del consumo de energía eléctrica residencial de la Región Cajamarca mediante modelos Holt-Winters. *Ingeniería Energética*, 40(3), 181-191. Universidad Nacional de Jaén y Universidad Nacional de Ingeniería.
- Jiménez Guerrero, J. F., Gázquez Abad, J. C., Sánchez Fernández, R. (2006). La capacidad predictiva en los métodos Box-Jenkins y Holt-Winters: una aplicación al sector turístico. *Revista Europea de Dirección y Economía de la Empresa*, 15(3), 185-198.
- Kerlinger, F. N. (2002). *Investigación del comportamiento: un enfoque científico*. McGraw-Hill.
- López Real, F. A. (2021). Comparación de la metodología de Box-Jenkins y el método de Holt-Winters para el pronóstico de series de tiempo univariado. *Superintendencia Nacional de Educación Superior Universitaria - SUNEDU*.
- Manterola, M. (2005, junio 6). *Procesos Estocásticos*. Obtenido de <http://www.marga.com.ar/6615/estocasticos.pdf>
- Mariño, M. D., Arango, A., Lotero, L., Jiménez, M. (2021). Modelos de series temporales para pronóstico de la demanda eléctrica del sector de explotación de minas y canteras en Colombia. *Revista EIA*, 18(35), 1-23.
- Murillo, W. (2008). *La investigación científica*. Recuperado de <http://www.monografias.com/trabajos15/invest-cientfica/investcientfica.shtm>
- Mejía Vásquez, E. J., Gonzales Chávez, S. (Año de publicación). Metodología de cálculo del modelo de suavización exponencial Holt-Winters [Figura]. En *Predicción del consumo de energía eléctrica residencial de la Región Cajamarca mediante modelos Holt-Winters*.
- Puerta Ventura, A. M., Alayo Vilcarromero, D. A. (2024). Implementación de mejoras en el pronóstico de demanda para la cadena de hoteles de Mountain Lodges of Perú (Trabajo de suficiencia profesional, Universidad Peruana de Ciencias Aplicadas). Asesor: N. Y. Salazar Villafuerte. Facultad de Negocios, Programa Académico de Administración y Finanzas, Programa Académico de Administración y Negocios Internacionales.
- Reyes Rodríguez, T. (2019). Aplicación de los modelos Box-Jenkins y Holt-Winters para el pronóstico de los caudales mensuales en el río Shullcas en la estación Chamisería, Huancayo-Perú. *Aporte Santiaguino*, 12(1), 70-80.
- Ríos, G. (2008). Universidad de Chile. Obtenido de Series de tiempo: https://www.u-cursos.cl/ingenieria/2010/1/CC52A/1/material_docente/bajar?id

- Rojas, S. L., Sánchez, R. G., Mata, O. A., Arana-Coronado, A., Estrada, A. (2019). Figure 1. Flowchart of the Box-Jenkins methodology. En Metodología Box-Jenkins para pronosticar los precios de huevo blanco pagados al productor en México.
- Schwarz, G. (2017). Metodología de la investigación científica. Editorial Alfa.
- Soriano, G. (2013). Obtenido de <https://prezi.com/qilwyg5ezlpe/metodologia-de-box-jenkins/>
- Vermorel, J. (2012, enero). LOKAD. Obtenido de <https://www.lokad.com/es/que-es-el-pronostico-de-series-de-tiempo>
- Veiga, C. P., Veiga, C. R. P., Catapan, A., Tortato, U., Da Silva, W. V. (2014). Demand forecasting in food retail: A comparison between the Holt-Winters and ARIMA models. WSEAS Transactions on Business and Economics, 11, 608-614.
- Yrigoyen, C. C. (2010). Econometría. Obtenido de Planteamiento de los modelos de series temporales: <https://econometriaii.files.wordpress.com/2010/01/modelos-de-series-temporales.pdf>

7. ANEXOS

7.1. Normas, Estándares y Regulaciones

7.1.1. Norma NTP-ISO 9001:2001

Los estándares internacionales de orientación sobre las técnicas estadísticas para la Norma NTP-ISO 9001:2001, basada en la ISO 9001:2000, está centrada en sistemas de gestión de calidad. Su propósito es ayudar a las organizaciones a implementar un sistema que asegure la mejora continua y la satisfacción del cliente.

Propósito de las Técnicas Estadísticas en ISO 9001:2001.- Las técnicas estadísticas en el contexto de la ISO 9001 sirven para:

- **Controlar la variabilidad de los procesos:** Identificar y reducir la variabilidad en los procesos para mejorar la calidad.
- **Tomar decisiones basadas en evidencia:** Aportan datos objetivos que apoyan la toma de decisiones informadas.
- **Optimización y mejora continua:** Facilitan la identificación de oportunidades de mejora y optimización de procesos.

Tipos de Técnicas Estadísticas en ISO 9001.- Las técnicas estadísticas en ISO 9001 pueden clasificarse en varias categorías, de acuerdo con su aplicación:

- **Técnicas de Recolección de Datos:** Incluyen muestreo y diseño de experimentos. Estas técnicas son esenciales para asegurar que los datos recolectados sean representativos y útiles para análisis posteriores.
- **Análisis de Datos:** Se utilizan gráficos de control, análisis de Pareto y otras herramientas estadísticas que permiten observar patrones y tendencias en los datos para tomar decisiones.
- **Técnicas de Predicción:** Aunque no son obligatorias en ISO 9001, el pronóstico mediante modelos estadísticos como el ARIMA puede ser útil para predecir la demanda y mejorar la planificación de recursos.

Beneficios de la Aplicación de Técnicas Estadísticas bajo ISO 9001

- **Reducción de Costos:** Al identificar las causas raíz de variabilidad y defectos, es posible reducir el desperdicio, mejorar la eficiencia y disminuir costos de producción.
- **Mejora en la Satisfacción del Cliente:** Asegurando productos o servicios de calidad constante, se logra satisfacer las expectativas del cliente de forma confiable.
- **Identificación de Problemas en Fase Temprana:** Mediante el uso de gráficos de control, se pueden detectar problemas en las primeras etapas del proceso, lo cual permite corregirlos antes de que afecten al cliente.

Herramientas Específicas de Técnicas Estadísticas

- **Control Estadístico de Procesos (CEP):** El CEP es esencial para monitorizar y controlar la calidad durante la producción mediante el uso de gráficos de control, que permiten visualizar el comportamiento de los procesos y detectar cuándo están fuera de control.
- **Análisis de Capacidad de Procesos:** Mediante el cálculo de índices como el C_{pk} y C_p , se puede evaluar si un proceso puede cumplir consistentemente con las especificaciones del cliente.
- **Análisis de Pareto:** Esta técnica ayuda a identificar las causas principales de problemas en procesos o productos, permitiendo enfocarse en las áreas que generan mayores beneficios si se mejoran.

Rol de las Técnicas Estadísticas en la Mejora Continua

- **Ciclo PDCA (Plan-Do-Check-Act):** Las técnicas estadísticas son esenciales en cada fase del ciclo de mejora continua. Durante la planificación (Plan), se pueden utilizar datos históricos para establecer metas; en la ejecución (Do), se monitorean los resultados; en la verificación (Check), se evalúan los datos recolectados; y en la acción (Act), se implementan mejoras basadas en análisis estadísticos.
- **Auditorías Internas y Externas:** La ISO 9001 requiere auditorías periódicas; el uso de estadísticas permite a los auditores evaluar de manera objetiva si los procesos cumplen con los requisitos y si están mejorando con el tiempo.

Limitaciones y Retos en la Implementación de Técnicas Estadísticas

- **Requerimiento de Capacitación:** La aplicación efectiva de las técnicas estadísticas requiere que el personal esté capacitado en estadísticas y en el uso de herramientas específicas.
- **Cultura de Toma de Decisiones Basada en Datos:** La implementación exitosa de la norma requiere un cambio de mentalidad hacia una cultura orientada a la mejora continua y a decisiones respaldadas por datos.
- **Adaptación a Variabilidad en Procesos:** No todos los procesos son fácilmente cuantificables, por lo que adaptar las técnicas estadísticas a diferentes tipos de procesos puede ser un reto.

7.1.2. Norma NTP-ISO 3534-1:2015

La Norma NTP-ISO 3534-1:2015 proporciona un glosario fundamental de términos estadísticos y símbolos utilizados en estadística general y en el cálculo de probabilidades. Esta norma es una herramienta esencial para la comprensión y aplicación de técnicas estadísticas en otros estándares internacionales, facilitando la comunicación y el uso adecuado de conceptos y notación en el ámbito de la gestión de calidad, la ciencia, y la ingeniería.

Definición de términos clave

- **Estadístico:** Función completamente especificada de variables aleatorias.
- **Estimador:** Estadístico utilizado para la estimación de un parámetro.
- **Estimador por intervalo:** Intervalo con un estadístico como límite superior y otro como límite inferior.
- **Intervalo de confianza:** Un estimador por intervalo (T_0, T_1) para el parámetro θ con los estadísticos T_0 y T_1 como límites. Se cumple que $P[T_0 < \theta < T_1] \geq 1 - \alpha$.
- **Estimado:** Valor observado de un estimador.
- **Error de estimación:** Diferencia entre el estimado y el parámetro o propiedad poblacional que se desea estimar.
- **Estimador de máxima verosimilitud:** Estimador asociado al valor del parámetro cuando la función de verosimilitud alcanza su valor máximo.
- **Función de verosimilitud:** Función de la densidad de probabilidad evaluada en los valores observados, considerada como función de los parámetros de la distribución.
- **Nivel de significancia α :** Máxima probabilidad de rechazar la hipótesis nula cuando esta es verdadera.
- **P-valor:** Probabilidad de obtener el valor del estadístico de prueba o uno más extremo en contra de la hipótesis nula.
- **Hipótesis nula H_0 :** Hipótesis que se evalúa en una prueba estadística.
- **Hipótesis alternativa H_A :** Conjunto de posibles distribuciones de probabilidad que no pertenecen a la hipótesis nula.

Importancia de la NTP-ISO 3534-1:2015 en estadística aplicada:

La NTP-ISO 3534-1:2015 es fundamental para la normalización de la terminología estadística en entornos técnicos y normativos, y es aplicable en diversos ámbitos como la gestión de calidad, la ingeniería y la investigación científica. Al definir términos y símbolos comunes, esta norma facilita la implementación coherente de técnicas estadísticas y asegura que las metodologías empleadas en distintos contextos mantengan uniformidad y precisión en su interpretación.

7.1.3. Normas adicionales relacionadas

- **ISO 3534-2 - Applied Statistics:** Define términos y simbolización en estadística aplicada, organizándolos en un marco conceptual y presentando un índice temático y alfabético.
- **ISO 16269-8 - Prediction Intervals:** Establece métodos para determinar intervalos de predicción para variables continuas.

- **ISO 2854 - Estimation and Tests for Means and Variances:** Trata la comparación y estimación de varianzas y medias, bajo la hipótesis de normalidad, y es aplicable a muestras independientes y aleatorias.
- **ISO 5479 - Tests for Normal Distribution Departure:** Proporciona métodos y pruebas para evaluar si una muestra sigue una distribución normal, asumiendo independencia entre observaciones.
- **ISO 2602 - Confidence Interval for the Mean:** Aborda la estimación de la media poblacional y el cálculo de intervalos de confianza en muestras donde la varianza poblacional es desconocida.

7.2. Restricciones Múltiples

- La precisión de los modelos predictivos depende significativamente de la calidad y cantidad de los datos históricos disponibles. En este estudio, los datos se extendieron desde febrero del 2001 hasta agosto de 2024, lo que pudo haber limitado la capacidad de los modelos para captar patrones de largo plazo. La ausencia de datos de mayor frecuencia o detalle pudo haber influido en la precisión de los pronósticos.
- El período de predicción, enfocado en los meses de septiembre a diciembre de 2024, restringe el alcance de las conclusiones a un horizonte temporal limitado. Si bien este marco permite un análisis detallado de corto plazo, proyecciones más extensas requerirían ajustes metodológicos y la consideración de factores externos.
- Aunque el modelo SARIMA es robusto para series temporales estacionales, puede no ser efectivo en presencia de cambios estructurales abruptos, como modificaciones drásticas en las tendencias o la estacionalidad. Además, su rendimiento puede verse comprometido si los datos contienen intervalos poco frecuentes o faltantes.
- La investigación no consideró explícitamente factores externos que podrían influir en el comportamiento del IPC en transporte, como cambios en las políticas gubernamentales, fluctuaciones en los precios internacionales de combustibles o eventos económicos inesperados. Esto limita la capacidad de los modelos para capturar dinámicas externas que podrían afectar los resultados.
- Para el modelo Holt-Winters, los valores iniciales asignados a la tendencia y los componentes estacionales influyen significativamente en la precisión del pronóstico. En el modelo SARIMA, las suposiciones de estacionariedad y ruido blanco en los residuos pueden no cumplirse completamente, lo que impacta la validez del modelo.

7.3. Código del Programa

```
1 # Cargamos las librerías necesarias
2 library(tidyverse)
3 library(forecast)
4 library(tseries)
5 library(ggplot2)
6 library(readxl)
7 library(tidyr)
8 library(zoo)
9 library(urca)
10 library(viridis)
11 library(dplyr)
12 library(scales)
13 library(lmtest)
14 library(knitr)
15 library(DT)
16
17 # Cargamos la data
18 ipc_data <- read_excel("C:/Users/Michell/Desktop/DECIMO CICLO/Seminario Capstone/Ultima
19   Entrega/IPC EN TRANSPORTE.xlsx",
20   col_types=c("date", "numeric"))
21 ipc_data <- ipc_data %>%
22   mutate(Fecha=as.Date(Fecha))
23
24 # Verificamos los nombres de las columnas
25 colnames(ipc_data)
26
27 ##### Analisis Exploratorio #####
28 summary(ipc_data)
29 head(ipc_data)
30 tail(ipc_data)
31 str(ipc_data)
32 any(is.na(ipc_data))
33
34 # Convertimos a una serie de tiempo
35 ts_data <- ts(ipc_data$IPC.Transporte, start=c(2001, 2), frequency=12)
36
37 # Grafico de la serie temporal original
38 ggplot(ipc_data, aes(x = Fecha, y = IPC.Transporte)) +
39   geom_line() +
40   labs(title = "Serie Temporal del IPC Transporte en Lima Metropolitana",
41     x = "Fecha",
42     y = "IPC") +
43   scale_x_date(date_breaks = "1 year", date_labels = "%Y") +
44   theme_minimal() +
45   theme(plot.title = element_text(hjust = 0.5))
46
47 ##### Suavizado Central #####
48 # Aplicamos el suavizado central tomando la media de 5 observaciones
49 ipc_data <- ipc_data %>%
50   mutate(IPC_suavizado = rollmean(IPC.Transporte, k = 5, fill = NA, align = "center"))
51
52 # Graficamos la serie de tiempo original y la suavizada
53 ggplot(ipc_data, aes(x = Fecha)) +
54   geom_line(aes(y = IPC.Transporte), color = "blue", size = 1) +
55   geom_line(aes(y = IPC_suavizado), color = "red", size = 1, linetype = "dashed") +
56   labs(
57     title = "Serie Temporal del IPC Transporte en Lima Metropolitana con Suavizado Central",
58     x = "Fecha", y = "IPC") +
```

```

1  scale_x_date(date_breaks = "1 year", date_labels = "%Y") +
2  theme_minimal() +
3  theme(legend.position = "bottom") +
4  scale_y_continuous(labels = scales::comma)+
5  theme(plot.title = element_text(hjust = 0.5))
6
7  # Reemplazamos los datos de IPC por los datos suavizados en los periodos especificos
8  ipc_data <- ipc_data %>%
9    mutate(IPC.Transporte = ifelse((Fecha >= as.Date("2003-01-01") & Fecha <=
10      as.Date("2003-05-01")),
11        IPC_suavizado, IPC.Transporte))
12
13 # Creamos una nueva tabla con las columnas Fecha e IPC
14 ipc_suavizado <- ipc_data %>%
15   select(Fecha, IPC.Transporte)
16
17 # Visualizamos la nueva tabla
18 print(ipc_suavizado)
19
20 # Convertimos la nueva tabla a una serie de tiempo
21 ipc_ts <- ts(ipc_suavizado$IPC.Transporte, start = c(2001, 2), frequency = 12)
22
23 # Graficamos la nueva serie de tiempo
24 ggplot(ipc_suavizado, aes(x = Fecha, y = IPC.Transporte)) +
25   geom_line(color = "blue") +
26   labs(title = "Serie Temporal del IPC Transporte en Lima Metropolitana con Suavizado",
27     x = "Fecha", y = "IPC") +
28   scale_x_date(date_breaks = "1 years", date_labels = "%Y") +
29   theme_minimal()+
30   theme(plot.title = element_text(hjust = 0.5))
31
32 ##### Analisis Exploratorio de la Serie Suavizada #####
33 summary(ipc_suavizado)
34 head(ipc_suavizado)
35 tail(ipc_suavizado)
36 str(ipc_suavizado)
37 any(is.na(ipc_suavizado))
38
39 # Boxplots por mes
40 colors <- viridis(12, option = "C") # Definimos los colores
41 boxplot(ipc_ts ~ cycle(ipc_ts), xlab = "Mes", ylab = "IPC",
42   main = "Boxplot del IPC por Mes", col = colors)
43
44 ## Funciones de autocorrelacion
45 # ACF
46 acf_vals <- acf(ipc_ts, lag.max = 24, plot = FALSE)
47 plot(acf_vals, main = "Funcin de Autocorrelacin (ACF) hasta 24 rezagos",
48   col = "steelblue", lwd = 2, ylim = c(-0.2, 1), xlab = "Rezago",
49   ylab = "Autocorrelacin")
50 abline(h = 0, col = "red", lwd = 2)
51 abline(h = c(-1.96/sqrt(length(ipc_ts)), 1.96/sqrt(length(ipc_ts))), col = "blue",
52   lty = 2, lwd = 2)
53
54 # PACF
55 pacf_vals <- pacf(ipc_ts, lag.max = 24, plot = FALSE)
56 plot(pacf_vals, main = "Funcin de Autocorrelacin Parcial (PACF) hasta 24 rezagos",
57   col = "steelblue", lwd = 2, ylim = c(-0.2, 1), xlab = "Rezago", ylab = "Autocorrelacin")
58 abline(h = 0, col = "red", lwd = 2)
59 abline(h = c(-1.96/sqrt(length(ipc_ts)), 1.96/sqrt(length(ipc_ts))), col = "blue",
60   lty = 2, lwd = 2)

```

```

1 # Descomposicion de la serie
2 ipc_ts_components <- decompose(ipc_ts)
3 plot(ipc_ts_components,
4       xlab = "Fecha",
5       ylab = "Valor")
6
7 # Test de Dickey-Fuller
8 adf_test <- adf.test(ipc_ts)
9 print(adf_test)
10
11 ## Transformacion Logaritmica ##
12 # Se agrega una constante mayor que el valor absoluto mnimo para constrestrar los valores
   negativos o cero
13 ipc_ts_adjusted <- ipc_ts + abs(min(ipc_ts)) + 1
14
15 # Se aplica la transformacion logaritmica
16 ipc_log <- log(ipc_ts_adjusted)
17
18 # Grafica de la serie original y su transformacion
19 par(mfrow = c(2, 1))
20 # Grafico de la serie original ajustada
21 plot(ipc_ts_adjusted, main = "Serie Original Ajustada", col = "blue", ylab = "Valores", xlab
   = "Tiempo")
22 # Grafico de la serie transformada logaritmicamente
23 plot(ipc_log, main = "Serie Transformada Logartmica", col = "green", ylab = "Logaritmo de
   Valores", xlab = "Tiempo")
24 par(mfrow = c(1, 1))
25
26 ##### METODO BOX JENKINS #####
27 # Se divide los datos en entrenamiento y prueba
28 train_size <- length(ipc_log) - 12
29 train_data <- ipc_log[1:train_size]
30 test_data <- ipc_log[(train_size + 1):length(ipc_log)]
31
32 # Funcion para calcular el MAPE, MAE y RMSE
33 calculate_metrics <- function(actual, predicted) {
34   mape <- mean(abs((actual - predicted) / actual)) * 100
35   mae <- mean(abs(actual - predicted))
36   rmse <- sqrt(mean((actual - predicted)^2))
37   return(list(MAPE = mape, MAE = mae, RMSE = rmse))
38 }
39 # Modelos Candidatos
40 # Modelo 1: SARIMA(0,1,1)(0,1,1)[12]
41 modelo1 <- Arima(train_data, order = c(0, 1, 1), seasonal = list(order = c(0, 1, 1), period
   = 12))
42 f1 <- forecast(modelo1, h = 12)
43 summary(modelo1)
44 coeftest(modelo1, df=Inf)
45 metrics1 <- calculate_metrics(test_data, f1$mean)
46 print(paste("MAPE del Modelo 1 (SARIMA(0,1,1)(0,1,1)[12]):", metrics1$MAPE))
47 print(paste("MAE del Modelo 1 (SARIMA(0,1,1)(0,1,1)[12]):", metrics1$MAE))
48 print(paste("RMSE del Modelo 1 (SARIMA(0,1,1)(0,1,1)[12]):", metrics1$RMSE))
49
50 # Modelo 2: SARIMA(1,0,1)(1,0,1)[12]
51 modelo2 <- Arima(train_data, order = c(1, 0, 1), seasonal = list(order = c(1, 0, 1), period
   = 12))
52 f2 <- forecast(modelo2, h = 12)
53 summary(modelo2)
54 coeftest(modelo2, df=Inf)
55 metrics2 <- calculate_metrics(test_data, f2$mean)

```

```

1 print(paste("MAPE del Modelo 2 (SARIMA(1,0,1)(1,0,1)[12]):", metrics2$MAPE))
2 print(paste("MAE del Modelo 2 (SARIMA(1,0,1)(1,0,1)[12]):", metrics2$MAE))
3 print(paste("RMSE del Modelo 2 (SARIMA(1,0,1)(1,0,1)[12]):", metrics2$RMSE))
4
5 # Modelo 3: SARIMA(2,0,0)(0,1,1)[12] (mantiene la estructura del modelo 3 original)
6 modelo3 <- Arima(train_data, order = c(2, 0, 0), seasonal = list(order = c(0, 1, 1), period
7   = 12))
8 f3 <- forecast(modelo3, h = 12)
9 summary(modelo3)
10 coeftest (modelo3,df=Inf)
11 metrics3 <- calculate_metrics(test_data, f3$mean)
12 print(paste("MAPE del Modelo 3 (SARIMA(2,1,0)(0,1,1)[12]):", metrics3$MAPE))
13 print(paste("MAE del Modelo 3 (SARIMA(2,1,0)(0,1,1)[12]):", metrics3$MAE))
14 print(paste("RMSE del Modelo 3 (SARIMA(2,1,0)(0,1,1)[12]):", metrics3$RMSE))
15
16 # Modelo 4: SARIMA(1,0,1)(0,1,1)[12]
17 modelo4 <- Arima(train_data, order = c(1, 0, 1), seasonal = list(order = c(0, 1, 1), period
18   = 12))
19 f4 <- forecast(modelo4, h = 12)
20 summary(modelo4)
21 coeftest (modelo4,df=Inf)
22 metrics4 <- calculate_metrics(test_data, f4$mean)
23 print(paste("MAPE del Modelo 4 (SARIMA(1,1,1)(1,1,1)[12]):", metrics4$MAPE))
24 print(paste("MAE del Modelo 4 (SARIMA(1,1,1)(1,1,1)[12]):", metrics4$MAE))
25 print(paste("RMSE del Modelo 4 (SARIMA(1,1,1)(1,1,1)[12]):", metrics4$RMSE))
26
27 #Modelo 5: SARIMA(0,0,1)(1,1,1)[12]
28 modelo5 <- Arima(train_data, order = c(0, 0, 1), seasonal = list(order = c(1, 1, 1), period
29   = 12))
30 f5 <- forecast(modelo5, h = 12)
31 summary(modelo5)
32 coeftest (modelo5,df=Inf)
33 metrics5 <- calculate_metrics(test_data, f5$mean)
34 print(paste("MAPE del Modelo 5 (SARIMA(1,1,0)(1,1,0)[12]):", metrics5$MAPE))
35 print(paste("MAE del Modelo 5 (SARIMA(1,1,0)(1,1,0)[12]):", metrics5$MAE))
36 print(paste("RMSE del Modelo 5 (SARIMA(1,1,0)(1,1,0)[12]):", metrics5$RMSE))
37
38 # Prueba de Ljung-Box
39 for (i in 1:5) {
40   modelo <- get(paste("modelo", i, sep=""))
41   ljung_box <- Box.test(residuals(modelo), lag = 12, type = "Ljung-Box")
42   print(paste("Prueba Ljung-Box para el Modelo", i, ":"))
43   print(ljung_box)
44 }
45
46 # Funcion para graficar los residuos
47 plot_residuales <- function(modelo, modelo_nombre) {
48   par(mfrow = c(2, 2))
49   # Grafico de Residuos
50   plot(residuals(modelo), main = paste("Residuales del", modelo_nombre),
51     ylab = "Residuos")
52   # ACF de Residuos
53   acf(residuals(modelo), main = paste("ACF de Residuos -", modelo_nombre))
54   # PACF de Residuos
55   pacf(residuals(modelo), main = paste("PACF de Residuos -", modelo_nombre))
56   # Grafico Q-Q de Residuos
57   qqnorm(residuals(modelo), main = paste("Q-Q de Residuos -", modelo_nombre))
58   qqline(residuals(modelo), col = "red")
59   # Prueba de Normalidad de Residuos (Shapiro-Wilk)
60   print(paste("Prueba de Shapiro-Wilk para el Modelo", modelo_nombre, ":"))
61   print(shapiro.test(residuals(modelo)))

```

```

1  par(mfrow = c(1, 1))
2  }
3  plot_residuales(modelo1, "Modelo 1")
4  plot_residuales(modelo2, "Modelo 2")
5  plot_residuales(modelo3, "Modelo 3")
6  plot_residuales(modelo4, "Modelo 4")
7  plot_residuales(modelo5, "Modelo 5")
8
9  ### Pronostico ###
10 # Obtenemos los pronosticos de septiembre a diciembre de 2024 usando el Modelo Optimo n2
11 f2_future <- forecast(modelo2, h = 4)
12
13 # Transformacion inversa para los pronosticos y los intervalos de confianza
14 f2_df <- data.frame(
15   Date = seq.Date(from = as.Date("2024-09-01"), by = "month", length.out = 4),
16   Forecast = exp(as.numeric(f2_future$mean)) - abs(min(ipc_ts)) - 1,
17   Lower80 = exp(as.numeric(f2_future$lower[, 1])) - abs(min(ipc_ts)) - 1,
18   Upper80 = exp(as.numeric(f2_future$upper[, 1])) - abs(min(ipc_ts)) - 1,
19   Lower95 = exp(as.numeric(f2_future$lower[, 2])) - abs(min(ipc_ts)) - 1,
20   Upper95 = exp(as.numeric(f2_future$upper[, 2])) - abs(min(ipc_ts)) - 1
21 )
22
23 # Secuencia de fechas para los datos de entrenamiento
24 train_dates <- seq.Date(from = as.Date("2002-02-01"), by = "month", length.out =
   length(train_data))
25
26 # Se crea el data.frame para los datos originales en la escala original
27 original_df <- data.frame(
28   Date = train_dates,
29   Value = exp(as.numeric(train_data)) - abs(min(ipc_ts)) - 1
30 )
31
32 # Grafica de los pronosticos junto con la serie temporal original
33 ggplot() +
34   # Serie original (entrenamiento) en la escala original
35   geom_line(data = original_df, aes(x = Date, y = Value), color = 'black') +
36   # Pronostico del Modelo 2 en la escala original
37   geom_line(data = f2_df, aes(x = Date, y = Forecast), color = 'red') +
38   # Intervalo de confianza del 80% (en la escala original)
39   geom_ribbon(data = f2_df, aes(x = Date, ymin = Lower80, ymax = Upper80), alpha = 0.2, fill
   = 'orange') +
40   # Intervalo de confianza del 95% (en la escala original)
41   geom_ribbon(data = f2_df, aes(x = Date, ymin = Lower95, ymax = Upper95), alpha = 0.1, fill
   = 'red') +
42   labs(
43     title = "Pronstico del Modelo SARIMA(1,0,1)(1,0,1) para Septiembre-Diciembre 2024",
44     x = "Fecha",
45     y = "Valor"
46   ) +
47   theme_minimal() +
48   theme(plot.title = element_text(hjust = 0.5))
49
50 # Mostramos la tabla de pronosticos usando knitr::kable()
51 kable(f2_df, caption = "Pronsticos para Septiembre-Diciembre 2024 (Modelo 2 SARIMA)")

```


7.4. Hojas de Datos

Fecha	IPC.Transporte
Feb-01	-0.2360
Mar-01	-0.0323
Abr-01	0.9445
May-01	-0.6814
Jun-01	-0.0685
Jul-01	0.3145
Ago-01	-0.3590
Set-01	-0.0945
Oct-01	-0.0487
Nov-01	-0.2384
Dic-01	1.2562
Ene-02	-0.5462
Feb-02	-0.0285
Mar-02	0.1128
Abr-02	-0.2472
May-02	-0.0077
Jun-02	0.0836
Jul-02	0.5691
Ago-02	-0.1022
Set-02	-0.3360
Oct-02	0.1197
Nov-02	-0.0326
Dic-02	0.6129
Ene-03	-0.4688
Feb-03	0.6904
Mar-03	8.9163
Abr-03	0.7075
May-03	-0.2431
Jun-03	0.1241
Jul-03	0.7131
Ago-03	-0.3733
Set-03	-0.1027
Oct-03	-0.2041
Nov-03	0.0107
Dic-03	0.8052
Ene-04	-0.5739
Feb-04	-0.0134
Mar-04	0.1209
Abr-04	-0.0798
May-04	-0.2178
Jun-04	0.0215
Jul-04	0.7791
Ago-04	-0.2737
Set-04	0.2297
Oct-04	0.6626

Fecha	IPC.Transporte
Nov-04	1.4637
Dic-04	1.1222
Ene-05	-0.2468
Feb-05	-0.2524
Mar-05	0.4873
Abr-05	-0.2224
May-05	0.1321
Jun-05	0.0539
Jul-05	0.7306
Ago-05	-0.2459
Set-05	0.1261
Oct-05	0.1980
Nov-05	0.4712
Dic-05	1.1089
Ene-06	-0.5166
Feb-06	-0.0991
Mar-06	0.0933
Abr-06	0.4670
May-06	-0.2181
Jun-06	0.0574
Jul-06	0.9613
Ago-06	-0.7039
Set-06	0.1260
Oct-06	-0.2026
Nov-06	0.2173
Dic-06	1.1221
Ene-07	-0.7453
Feb-07	0.0113
Mar-07	-0.1078
Abr-07	0.2133
May-07	-0.2899
Jun-07	-0.0130
Jul-07	0.9160
Ago-07	-0.3705
Set-07	-0.2655
Oct-07	0.0586
Nov-07	0.1126
Dic-07	1.4658
Ene-08	-0.7607
Feb-08	-0.0770
Mar-08	0.3594
Abr-08	-0.2600
May-08	0.4380
Jun-08	0.5446
Jul-08	0.8106

Fecha	IPC.Transporte
Ago-08	0.6119
Set-08	3.1626
Oct-08	0.6111
Nov-08	0.0313
Dic-08	0.9335
Ene-09	-0.8743
Feb-09	0.2013
Mar-09	-0.1863
Abr-09	0.0536
May-09	-0.4844
Jun-09	-0.0292
Jul-09	0.6136
Ago-09	-0.3138
Set-09	-0.2636
Oct-09	-0.1225
Nov-09	-0.0534
Dic-09	1.2812
Ene-10	-0.5232
Feb-10	-0.1236
Mar-10	0.2329
Abr-10	-0.4156
May-10	0.2921
Jun-10	0.0240
Jul-10	0.7201
Ago-10	-0.1967
Set-10	-0.1374
Oct-10	0.2610
Nov-10	-0.3998
Dic-10	2.2177
Ene-11	-0.7730
Feb-11	0.0766
Mar-11	0.2281
Abr-11	0.2574
May-11	-0.2323
Jun-11	0.1840
Jul-11	0.6257
Ago-11	0.0300
Set-11	0.7515
Oct-11	0.0671
Nov-11	0.1375
Dic-11	2.1926
Ene-12	-0.8740
Feb-12	0.0076
Mar-12	0.4326
Abr-12	-0.1427
May-12	-0.0146
Jun-12	0.1074
Jul-12	0.8718

Fecha	IPC.Transporte
Ago-12	-0.0531
Set-12	-0.1402
Oct-12	0.1537
Nov-12	-0.3127
Dic-12	1.3302
Ene-13	-0.6972
Feb-13	0.0074
Mar-13	0.2661
Abr-13	0.1154
May-13	-0.1074
Jun-13	0.2438
Jul-13	0.9320
Ago-13	-0.2206
Set-13	-0.1345
Oct-13	0.1541
Nov-13	0.2343
Dic-13	1.0938
Ene-14	-0.6030
Feb-14	0.0753
Mar-14	0.1567
Abr-14	0.0681
May-14	-0.0916
Jun-14	0.1264
Jul-14	0.6352
Ago-14	-0.3152
Set-14	0.0274
Oct-14	0.0713
Nov-14	0.0342
Dic-14	1.0193
Ene-15	-0.5120
Feb-15	0.0121
Mar-15	-0.0563
Abr-15	-0.0267
May-15	-0.2438
Jun-15	0.0235
Jul-15	0.5106
Ago-15	-0.1037
Set-15	-0.1365
Oct-15	0.1092
Nov-15	-0.0032
Dic-15	0.9240
Ene-16	-0.6842
Feb-16	-0.1074
Mar-16	0.0861
Abr-16	0.0047
May-16	0.0912
Jun-16	0.0432
Jul-16	0.7865

Fecha	IPC.Transporte
Ago-16	-0.0458
Set-16	-0.0513
Oct-16	-0.0437
Nov-16	0.2143
Dic-16	0.8657
Ene-17	-0.4732
Feb-17	0.0754
Mar-17	0.0257
Abr-17	0.0167
May-17	-0.0037
Jun-17	0.0352
Jul-17	0.5478
Ago-17	-0.0732
Set-17	0.0354
Oct-17	-0.0563
Nov-17	-0.0178
Dic-17	0.9852
Ene-18	-0.6573
Feb-18	-0.0374
Mar-18	0.1473
Abr-18	0.0154
May-18	0.0721
Jun-18	0.0456
Jul-18	0.6143
Ago-18	-0.0153
Set-18	0.0024
Oct-18	0.0567
Nov-18	-0.0231
Dic-18	1.0934
Ene-19	-0.4256
Feb-19	0.0182
Mar-19	0.0943
Abr-19	-0.0321
May-19	0.0514
Jun-19	0.0457
Jul-19	0.6934
Ago-19	-0.0754
Set-19	0.0127
Oct-19	-0.0413
Nov-19	0.0346
Dic-19	1.1345
Ene-20	-0.5783
Feb-20	-0.0417
Mar-20	0.0218
Abr-20	0.0342
May-20	-0.0124
Jun-20	0.0483
Jul-20	0.7321

Fecha	IPC.Transporte
Ago-20	-0.0835
Set-20	-0.0356
Oct-20	0.0281
Nov-20	0.0213
Dic-20	1.2034
Ene-21	-0.4821
Feb-21	0.0173
Mar-21	0.0452
Abr-21	-0.0214
May-21	0.0315
Jun-21	0.0248
Jul-21	0.6832
Ago-21	-0.0542
Set-21	0.0342
Oct-21	0.0195
Nov-21	0.0127
Dic-21	1.0924
Ene-22	-0.5231
Feb-22	0.0285
Mar-22	0.0432
Abr-22	-0.0146
May-22	0.0124
Jun-22	0.0473
Jul-22	0.7254
Ago-22	-0.0723
Set-22	-0.0321
Oct-22	0.0341
Nov-22	0.0274
Dic-22	1.1234
Ene-23	-0.4728
Feb-23	0.0257
Mar-23	0.0324
Abr-23	-0.0417
May-23	0.0215
Jun-23	0.0362
Jul-23	0.6893
Ago-23	-0.0654
Set-23	0.0312
Oct-23	0.0128
Nov-23	0.0184
Dic-23	1.0453
Ene-24	-0.2869
Feb-24	0.4085
Mar-24	0.8099
Abr-24	0.1275
May-24	0.1083
Jun-24	0.2499
Jul-24	0.5884
Ago-24	-0.1639